

LAPORAN UAS
MATA KULIAH *MACHNE LEARNING* I

**STUDI KOMPARASI *MACHINE LEARNING* (HOG-SVM) DAN
BERBAGAI ARSITEKTUR *DEEP LEARNING* PADA
KLASIFIKASI MORFOLOGI DAUN SUKULEN**

Dosen Pengampu:

Erika Maulidiya, S.Kom., M.Kom.



Oleh:

Noviana Nur Aisyah 2310817120005

**PROGRAM STUDI TEKNOLOGI INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS LAMBUNG MANGKURAT
BANJARMASIN**

2026

DAFTAR ISI

DAFTAR ISI	2
DAFTAR GAMBAR	5
DAFTAR TABEL.....	6
BAB I PENDAHULUAN	7
1.1 Latar Belakang	7
1.2 Rumusan Masalah	9
1.3 Tujuan.....	9
1.4 Manfaat.....	9
BAB II <i>DATASET</i>	10
2.1 Deskripsi <i>Dataset</i>	10
2.2 Statistik <i>Dataset</i>	13
BAB III PREPROCESSING DATA	15
3.1 <i>Data Cleaning & Cropping</i>	15
3.2 <i>Data Augmentation & Penanganan Imbalanced Data</i>	15
3.3 <i>Image Standardization & Normalization</i>	16
3.4 <i>Data Split</i>	17
BAB IV METODE <i>MACHINE LEARNING</i>	18
4.1 Kajian Jurnal Terkait	18
4.2 Metode.....	20
4.3 <i>Workflow</i>	20
4.4 Parameter Model	21
4.5 Hasil Evaluasi.....	22
4.6.1 Evaluasi Model Terbaik	22
4.6.2 Analisis <i>Overfitting</i>	24

4.6 Kelebihan dan Kelemahan Metode	25
4.7.1 Kelebihan	25
4.7.2 Kelemahan	25
BAB V PENGEMBANGAN <i>DEEP LEARNING</i>	26
5.1 Kajian Jurnal Terkait	26
5.2 Model	29
5.3 Arsitektur Jaringan	31
5.4 Skenario Pelatihan dan <i>Hyperparameter</i>	31
5.5 Hasil dan Evaluasi	33
5.6 Kelebihan dan Kelemahan Model	33
BAB VI <i>WORKFLOW</i>	36
6.1 Diagram <i>Workflow</i>	36
6.2 Tahapan <i>Workflow</i>	37
6.2.1 Pengumpulan Dataset	37
6.2.2 <i>Preprocessing</i> Data	37
6.2.3 Penerapan Metode <i>Machine Learning</i>	37
6.2.4 Penerapan Metode <i>Deep Learning</i>	38
6.2.5 Evaluasi Model	38
6.2.6 Perbandingan Hasil dan Kesimpulan Model Terbaik	38
BAB VII HASIL DAN EVALUASI MODEL	39
7.1 Metriks Evaluasi	39
7.2 Hasil Model <i>Machine Learning</i>	39
7.3 Hasil Model <i>Deep Learning</i>	39
BAB VIII VISUALISASI HASIL	43
8.1 Grafik Kurva Pembelajaran (<i>Learning Curve</i>) Model Terbaik	43
8.2 <i>Confusion Matrix</i> Keseluruhan Model	43

8.3 Grafik Perbandingan Performa Keseluruhan	50
BAB IX PEMBAHASAN.....	51
9.1 Analisis Performa Model Terbaik	51
9.2 Komparasi <i>Machine Learning</i> Konvensional dan <i>Deep Learning</i>	51
9.3 Kendala Eksperimen dan Analisis Kelemahan Model	52
9.4 Peluang Pengembangan ke Depan	53
BAB X DEMO PROGRAM	55
10.1 Bahasa Pemrograman dan <i>Library</i> yang Digunakan.....	55
10.2 Cara Menjalankan Program.....	55
10.3 Tampilan Hasil Program.....	55
BAB XI KESIMPULAN	60
5.1 Kesimpulan.....	60
DAFTAR PUSTAKA	62
LAMPIRAN.....	66
Tautan GitHub	66
Tautan <i>Dataset</i>	67
Screenshot Program	68
Potongan Kode VGG16	71
Hasil Evaluasi Tambahan	72

DAFTAR GAMBAR

Gambar 2.1 Sukulen Daun Runcing	12
Gambar 2.2 Sukulen Daun Runcing	12
Gambar 2.3 Sukulen Daun Bulat	12
Gambar 2.4 Sukulen Daun Bulat	13
Gambar 4.1 <i>Confusion Matrix</i> SVM HOG saat UTS	23
Gambar 4.2 <i>Learning Curve</i> SVM HOG saat UTS	24
Gambar 4.1 Arsitektur Jaringan pada <i>Deep Learning</i>	31
Gambar 6.1 Diagram Alur Kerja	36
Gambar 8.1 <i>Learning Curve</i> Model VGG16	43
Gambar 8.2 <i>Confusion Matrix</i> Model SVM HOG.....	44
Gambar 8.3 <i>Confusion Matrix</i> Model CNN Klasik	45
Gambar 8.4 <i>Confusion Matrix</i> Model MobileNetV2	46
Gambar 8.5 <i>Confusion Matrix</i> Model VGG16	47
Gambar 8.6 <i>Confusion Matrix</i> Model ResNet50	48
Gambar 8.7 <i>Confusion Matrix</i> Model CNN SVM.....	49
Gambar 8.8 Grafik Perbandingan Akurasi Keseluruhan Model Klasifikasi	50
Gambar 10.1 Halaman Utama Program	56
Gambar 10.2 Proses <i>Input</i> dan <i>Output</i> dari Program	57
Gambar 10.3 Proses <i>Input</i> dan <i>Output</i> dari Program	58

DAFTAR TABEL

Tabel 2.1 Kelas <i>Dataset</i>	10
Tabel 2.2 Tabel Perbandingan Data.....	13
Tabel 4.1 Kajian Jurnal Terkait Metode <i>Machine Learning</i> Konvensional	18
Tabel 4.2 Parameter Model SVM HOG saat UTS	21
Tabel 5.1 Kajian Jurnal Terkait Metode <i>Deep Learning</i>	26
Tabel 7.1 Hasil Model CNN Klasik	39
Tabel 7.2 Hasil Model MobileNet50.....	40
Tabel 7.3 Hasil Model VGG16	40
Tabel 7.4 Hasil Model ResNet50	41
Tabel 7.5 Hasil Model CNN SVM.....	41

BAB I

PENDAHULUAN

1.1 Latar Belakang

Sukulen merupakan jenis tanaman yang dapat berkembang dengan baik dengan sedikit air, karena sukulen tidak perlu sering disiram. Sukulen juga tumbuh subur di berbagai lokasi, termasuk gurun yang panas. Merawat sukulen tidak sulit jika memperhatikan suhu dan kelembapan yang dibutuhkan sukulen [1]. Identifikasi spesies sukulen secara visual cukup menantang karena tingginya tingkat kemiripan antar kelas. Hal ini didukung oleh penelitian [2] yang menyoroti bahwa kerumitan morfologi daun (ukuran, bentuk, tekstur, warna) dapat sangat membingungkan secara visual karena tingginya tingkat kemiripan antar-spesies dan variasi di dalam satu spesies itu sendiri. Dalam kasus ini, saya membedakan "Daun Runcing" (ujung tajam, berduri, bertekstur garis/bintik) dengan "Daun Bulat" (ujung tumpul, permukaan halus polos, tebal berisi). Kesalahan identifikasi berujung pada kesalahan perawatan. Dataset ini dibuat secara spesifik agar model komputasi dapat memisahkan fitur morfologi tersebut secara objektif. Penelitian oleh [2] juga menyatakan bahwa otomatisasi klasifikasi daun tanaman adalah sebuah upaya baru yang bertujuan untuk melampaui keterbatasan keahlian manusia dan identifikasi manual.

Dalam hal ini, digunakan model *Machine Learning* karena dapat secara otomatis mempelajari fitur-fitur yang diekstraksi dari gambar daun. Dengan mengekstraksi informasi visual yang spesifik (seperti lekukan bentuk, pola urat, dan tekstur permukaan), algoritma seperti SVM dan KNN dapat membedakan antar spesies tanaman dengan akurasi yang sangat tinggi [3]. Sistem klasifikasi daun sering kali dihadapkan pada variasi gambar di dunia nyata, di mana algoritma harus dilatih sedemikian rupa karena objek daun yang difoto di alam bebas akan memiliki pencahayaan yang tidak merata serta latar belakang visual yang bising/kompleks.

Berdasarkan penelitian anatomi daun sukulen oleh [4], terbukti bahwa anatomi dan perbedaan morfologi daun secara fisik, khususnya ketebalan jaringan sel penyimpan air, secara langsung menentukan *Hydraulic Capacitance* atau kapasitas menahan air pada tanaman. Jaringan hidrolik pada daun sukulen yang tebal

memiliki toleransi hidrasi dan strategi menahan stres kekeringan yang jauh berbeda dengan daun berstruktur lain. Dengan demikian, pengenalan bentuk daun melalui algoritma *Machine Learning* dalam sistem ini merupakan klasifikasi yang krusial untuk menentukan profil hidrolik tanaman secara otomatis. Melalui identifikasi bentuk ini, pengguna dapat diberikan panduan rekomendasi *water management* yang tepat dan sesuai profil biologisnya agar tanaman tidak salah rawat. Kemudian, penelitian yang dilakukan oleh [5] menegaskan bahwa sifat struktural daun seperti rasio luas permukaan dan kapasitas penyimpanannya sangat menentukan strategi adaptasi tanaman dalam menghadapi stress air. Melalui prinsip fisiologis ini, model klasifikasi membagi daun ke dalam kelas sederhana seperti “Daun Bulat” dan “Daun Runcing”. Pendekatan ini memfasilitasi pengguna awam untuk dengan mudah mengenali adaptasi fisik penyimpan air pada tanaman, sehingga mereka bisa memberikan volume air dan intensitas cahaya matahari harian yang paling sesuai dengan strategi morfologis asli tanaman tersebut.

Seiring dengan kompleksitas variasi gambar di dunia nyata, seperti pencahayaan yang tidak merata dan latar belakang yang bising (*noise*), metode ekstraksi fitur manual seringkali menemui batasan. Oleh karena itu, pendekatan *Deep Learning*, seperti *Convolutional Neural Network* (CNN) dan arsitektur *Transfer Learning* seperti MobileNetV2, menjadi sangat relevan. CNN dapat memproses nilai piksel mentah (*raw data*) secara langsung [6], di mana CNN mempelajari dan mengekstraksi fitur visual secara hierarkis secara otomatis [7], sehingga sepenuhnya menghilangkan proses manual yang rumit dalam memilih dan mengekstraksi fitur [8]. Sementara itu, MobileNet adalah arsitekturnya yang sangat ringan (*lightweight*), di mana model ini dirancang khusus untuk secara drastis mengurangi ukuran parameter dan beban komputasi, serta mempercepat waktu prediksi, namun tetap mempertahankan tingkat akurasi yang tinggi [6]. Karena menggunakan lebih sedikit memori dan daya, MobileNet sangat cocok dan populer diimplementasikan pada perangkat bersumber daya rendah seperti ponsel pintar (*smartphones*) dan komputer berdaya rendah [6] [9] [10]. Penelitian ini disusun untuk menerapkan, menggabungkan, serta membandingkan kemampuan metode *machine learning* dan *deep learning* dalam mengatasi tantangan identifikasi visual pada tanaman sukulen.

1.2 Rumusan Masalah

- 1) Bagaimana cara membedakan fitur visual morfologi daun sukulen (yang memiliki tingkat kemiripan bentuk?)
- 2) Bagaimana performa algoritma *Support Vector Machine* (SVM) yang dikombinasikan dengan ekstraksi fitur *Histogram of Oriented Gradients* (HOG) dalam klasifikasi citra daun sukulen?
- 3) Skenario parameter apa yang menghasilkan model SVM paling optimal dan terhindar dari indikasi *overfitting*?

1.3 Tujuan

- 1) Mengukur tingkat akurasi metode *machine learning* konvensional (SVM) yang menggunakan fitur HOG dalam membedakan kelas daun bulat dan daun runcing pada citra sukulen.
- 2) Mengevaluasi dan membandingkan secara kuantitatif performa metode *deep learning* terhadap model *machine learning* yang dibangun.
- 3) Mengetahui seberapa tinggi tingkat optimalisasi yang dihasilkan dari pengujian beberapa skenario *hyperparameter* pada model *deep learning*.

1.4 Manfaat

- 1) Manfaat Teoretis

Memberikan wawasan empiris dan literatur tambahan mengenai perbandingan serta kombinasi kinerja algoritma *machine learning* konvensional dan *deep learning* dalam bidang visi komputer pertanian (botani).

- 2) Manfaat Praktis

Menghasilkan landasan model cerdas yang di masa depan dapat dikembangkan menjadi aplikasi pendeteksi tanaman, sehingga memfasilitasi pengguna awam untuk mengenali adaptasi fisik sukulen dan memberikan volume air harian yang paling sesuai dengan morfologi.

BAB II

DATASET

2.1 Deskripsi *Dataset*

Penelitian ini menggunakan *Dataset* Citra Morfologi Sukulen. *Dataset* ini secara spesifik mengumpulkan citra digital dari berbagai spesies tanaman sukulen yang diklasifikasikan ke dalam dua kelas utama berdasarkan morfologi visual daunnya. *Dataset* diambil secara langsung di rumah yang beralamat di Jl. Jahri Saleh. Meskipun literatur sebelumnya mengklasifikasikan adaptasi daun berdasarkan parameter anatomi mikroskopis (seperti *Saturated Water Content*), sistem algoritma *machine learning* hanya beroperasi pada ekstraksi fitur visual dua dimensi berskala makroskopis. Dengan demikian, pembagian kelas pada *dataset* ini ditetapkan sebagai representasi visual dari sifat fisiologis tersebut. Klasifikasi didasarkan pada fitur bentuk dan tekstur permukaan yang dapat diekstraksi secara matematis oleh model komputasi.

Tabel 2.1 Kelas *Dataset*

<i>Pointy Leaf</i>	
Definisi	Mewakili spesies sukulen yang secara visual memiliki bentuk daun menyempit di bagian ujung hingga membentuk sudut lancip. Secara biologis, bentuk fisik yang kaku dan bersudut ini merepresentasikan strategi adaptasi pertahanan fisik terhadap kekeringan, yang umumnya memiliki metrik penyimpanan air lebih rendah dibandingkan daun bulat.
Karakteristik	Memiliki garis batas tepi (<i>edge</i>) yang tegas dan bersudut. Permukaan atau pinggiran daun sering kali memiliki tekstur tambahan yang menonjol, seperti duri halus, bintik kasar, atau garis berpola, yang secara matematis akan menghasilkan nilai deteksi sudut dan tepi (<i>corner/edge detection</i>) yang tinggi pada algoritma.
Contoh	Haworthia (<i>Zebra plant</i>), Aloe vera berukuran kecil, Agave, atau jenis roset yang ujungnya memiliki titik meruncing tajam seperti pada Echeveria.

Pelabelan	Selama gambar menampilkan daun yang ujungnya meruncing tajam atau memiliki dominasi fitur tekstur/duri tajam pada permukaannya, gambar tersebut mutlak diklasifikasikan ke dalam kelas ini.
<i>Round Leaf</i>	
Definisi	Mewakili spesies sukulen yang memiliki bentuk daun membulat, oval, atau silindris tumpul tanpa adanya sudut lancip yang terdefinisi jelas pada bagian ujungnya. Secara biologis, bentuk daun yang tebal dan berisi ini adalah indikator utama tingginya rasio jaringan penyimpan air (<i>hydrenchyma</i>), yang memungkinkannya menampung volume air secara masif sebagai penyangga hidrolik.
Karakteristik	Memiliki kontur melengkung yang sangat halus (kurva). Permukaan daun umumnya polos, licin, dan tidak memiliki tekstur menonjol atau duri, sehingga gradien warna atau intensitas pikselnya jauh lebih merata.
Contoh	<i>Pachyphytum oviferum</i> (Moonstones), <i>Graptopetalum amethystinum</i> , atau beberapa jenis <i>Sedum</i> berdaun tumpul.
Pelabelan	Gambar harus murni menampilkan daun dengan ujung yang tumpul/membulat, tebal berisi (<i>fleshy</i>), serta memiliki permukaan yang halus tanpa elemen bersudut tajam sedikit pun (termasuk ketiadaan duri pada batang).

1) Kondisi Pengambilan

Perangkat → Foto diambil menggunakan kamera ponsel Samsung A54.

Sudut Pandang (*Angle*) → Pengambilan gambar dilakukan dari sudut pandang atas (*top-down*), samping dan 45 derajat.

Pencahayaan → Foto diambil di area terbuka dengan mengandalkan cahaya matahari alami saat siang hari dan cahaya lampu saat malam.

2) Aturan *Labelling*


Sistem Penamaan → Setiap citra diberi label unik dengan format ID.Varian.jpg.

Identitas Induk → Angka sebelum titik (ID) merujuk pada tanaman asli yang berbeda, sedangkan angka setelah titik (Varian) menunjukkan hasil augmentasi dari tanaman induk tersebut (misal: .0 adalah asli, .1 adalah hasil rotasi).


Target Label → Dalam pengolahan data, kelas Daun Runcing dipetakan sebagai label 0 dan Daun Bulat sebagai label 1.



Gambar 2.1 Sukulen Daun Runcing



Gambar 2.2 Sukulen Daun Runcing



Gambar 2.3 Sukulen Daun Bulat



Gambar 2.4 Sukulen Daun Bulat

2.2 Statistik *Dataset*

1) Jenis Data

Jenis data yang digunakan dalam penelitian ini adalah data citra digital berekstensi .jpg.

2) Jumlah Fitur

Jumlah fitur yang digunakan dalam penelitian ini bergantung pada arsitektur pemodelan yang diterapkan. Pada pemodelan *machine learning* konvensional (SVM) berbasis piksel mentah (*raw pixels*), dimensi citra diubah menjadi 64x64 piksel dengan 3 *channel* warna (RGB) dan diratakan (*flatten*), sehingga menghasilkan vektor 1 dimensi yang berisi tepat 12.288 fitur numerik. Sementara itu, untuk model SVM berbasis HOG, panjang vektor fiturnya menyesuaikan dengan parameter orientasi dan ukuran sel matriks yang telah didefinisikan. Kemudian, pada pemodelan *deep learning*, *input* data tidak diratakan di awal, melainkan dipertahankan sebagai representasi matriks spasial berukuran 224x224 piksel dengan 3 *channel* warna (RGB). Representasi matriks ini memungkinkan jaringan saraf tiruan untuk mempelajari pola visual secara hierarkis.

3) Tabel Perbandingan Data

Tabel 2.2 Tabel Perbandingan Data

Kelas	Jumlah Data Awal	Jumlah Data Akhir	Persentase Akhir
Daun Runcing	317 citra	1550 citra	50%
Daun Bulat	303 citra	1550 citra	50%

Total	620 citra	3100 citra	100%
-------	-----------	------------	------

BAB III

PREPROCESSING DATA

Bab ini menjelaskan rangkaian tahapan persiapan data citra mentah sebelum dimasukkan ke dalam arsitektur model *machine learning* dan *deep learning*. Proses *preprocessing* ini sangat krusial untuk menjamin pemusatan objek, meningkatkan variasi data, penyeragaman dimensi, hingga optimalisasi distribusi kelas saat pengujian.

3.1 Data Cleaning & Cropping

Tahap awal persiapan data dilakukan melalui seleksi visual (*data cleaning*) untuk mengeliminasi citra yang mengalami *motion blur* parah, gangguan pencahayaan ekstrem, atau ketidaksesuaian objek tanaman. Selanjutnya, diterapkan metode *center crop* sebesar 70% pada area tengah gambar. Langkah ini bertujuan untuk membuang elemen latar belakang (*background noise*) yang tidak relevan (seperti pot, tanah berlebih, atau objek sekitar) dan memfokuskan porsi matriks gambar pada karakteristik morfologi utama daun sukulen.

3.2 Data Augmentation & Penanganan Imbalanced Data

Pada kondisi awal, *dataset* mengalami ketidakseimbangan jumlah sampel (*imbalanced data*) antar-kelas. Dalam hal ini, untuk mengatasi potensi bias model terhadap kelas mayoritas serta memperkaya variasi visual, dilakukan teknik data *augmentation* secara masif pada kumpulan data asli. Manipulasi geometris yang diterapkan meliputi:

- *Random Rotation*

Memutar posisi citra untuk mensimulasikan sudut pengambilan foto yang bervariasi.

- *Horizontal Flip*

Membalik citra secara mendatar untuk melatih invariansi spasial model.

- *Brightness Adjustment*

Mengubah intensitas cahaya pada citra untuk mensimulasikan perbedaan kondisi pencahayaan.

Pemilihan rasio ekspansi *dataset* sebesar 5 kali lipat (dari 620 citra awal menjadi 3.100 citra) didasarkan pada landasan empiris dari penelitian terdahulu di bidang

visi komputer botani. Pertama, merujuk pada studi klasifikasi tanaman sukulen sebelumnya, di mana *dataset* diekspansi sebanyak 5 kali lipat (dari 691 citra awal) menggunakan teknik *random horizontal flip* untuk memperkaya representasi bentuk tanaman [11]. Kedua, justifikasi ini juga diperkuat oleh studi pengenalan penyakit pada spesies daun anggur, di mana total 500 citra diperbanyak secara ekuivalen menjadi 2.500 citra (5 kali lipat) melalui penerapan empat teknik augmentasi terpisah, termasuk pencerminan (*mirroring*) [12].

Mengacu pada bukti literatur tersebut, penerapan sirkuit augmentasi 5 kali lipat dalam penelitian ini dinilai merupakan konfigurasi yang ideal. Melalui tahapan ini, *dataset* berhasil diseimbangkan dan ditingkatkan volumenya secara signifikan menjadi total 3.100 citra (tersimpan pada direktori *sukulen_augmented*), yang sangat memadai untuk melatih arsitektur *deep learning*.

3.3 Image Standardization & Normalization

Seluruh citra hasil augmentasi melewati tahap standarisasi dimensi dan nilai piksel untuk memenuhi spesifikasi matematis dari lapisan *input* jaringan saraf.

- *Resize*

Mengubah resolusi seluruh citra dari ukuran aslinya menjadi dimensi homogen 224 x 224 piksel dengan 3 saluran warna (RGB). Penyeragaman ini disesuaikan dengan standar dimensi masukan (*expected input size*) arsitektur *deep learning*. Pemilihan ketetapan dimensi ini didasarkan pada tiga justifikasi utama yang merujuk pada standar literatur pemrosesan citra digital. Pertama, dimensi 224x224 merupakan standar ukuran masukan (*expected input size*) yang diwajibkan oleh mayoritas arsitektur *Convolutional Neural Network* (CNN) dan *Transfer Learning* umum, termasuk VGG-16, VGG-19, hingga MobileNetV2 yang dieksplorasi dalam penelitian ini [7] [13]. Kedua, memperkecil ukuran gambar menjadi kumpulan data dengan resolusi matriks yang homogen terbukti secara empiris dapat mengurangi beban komputasi, sehingga mempercepat proses pelatihan model secara signifikan [14]. Ketiga, standarisasi resolusi matriks yang seragam ini sangat krusial untuk memastikan konsistensi masukan di seluruh skenario algoritma yang diuji, yang pada akhirnya berperan penting

dalam meningkatkan kemampuan generalisasi model saat dihadapkan pada data pengujian baru [7].

- *Rescaling*

Mengubah skala nilai intensitas piksel asli yang berada pada rentang 0–255 menjadi rentang dinamis 0 hingga 1. Proses penyesuaian ini dilakukan langsung pada lapisan awal model untuk mempercepat proses konvergensi fungsi *loss* selama *training*.

3.4 Data Split

Pada pemodelan deep learning, dataset tidak hanya dibagi dua, melainkan dipisah secara sistematis menjadi tiga set data dengan proporsi 80:10:10, yaitu:

- Data Latih (Training)
80% (2.480 citra) digunakan untuk melatih dan memperbarui parameter bobot (weights) jaringan model.
- Data Validasi (Validation)
10% (310 citra) digunakan sebagai data pengawasan selama proses pelatihan berlangsung. Data ini berfungsi untuk memantau nilai akurasi dan loss pada setiap epoch agar pelatihan dapat dihentikan secara otomatis (Early Stopping) jika performa model mulai menurun.
- Data Uji (Testing)
10% (310 citra) digunakan murni untuk evaluasi klasifikasi metrik akhir. Citra pada data uji adalah data yang sama sekali belum pernah dilihat oleh model (unseen data) selama tahap pelatihan maupun validasi.

BAB IV

METODE MACHINE LEARNING

4.1 Kajian Jurnal Terkait

Tabel 4.1 Kajian Jurnal Terkait Metode *Machine Learning* Konvensional

No	Judul	Penulis	Masalah	Dataset	Metode	Hasil	Keterkaitan
1	<i>Support Vector Machine Based Classification of Medicinal Plants Using Leaf Features</i> (2017)	D Venkataraman & mangayarkarasi N [15]	Banyak kemiripan visual antar daun, sehingga identifikasi tanaman secara manual menjadi sulit bagi orang awam.	Ratusan sampel citra daun dari berbagai spesies yang difoto secara mandiri.	<i>Histogram of Oriented Gradients</i> (HOG) dikombinasikan dengan fitur tekstur (GLCM). Klasifikasi menggunakan algoritma SVM.	Algoritma SVM berhasil membedakan berbagai spesies daun berdasarkan ekstraksi fitur bentuk dan teksturnya.	Jurnal ini merupakan referensi paling identik dengan metode saya. Jurnal ini memvalidasi penggunaan fitur HOG yang dipadukan dengan SVM. Namun, di dalam jurnal ini HOG digunakan untuk membedakan daun obat.
2	<i>Assessment of three broadleaf weed species classification in rice field using UAV hyperspectral imaging and machine learning</i> (2025)	Nursyazyl a Sulaiman, Nik Norasma Che'Ya, Abdul Shukor Juraimi, Nisfariza Mohd Noor, Rhushalshafira	Invasi gulma berdaun lebar (<i>broadleaf weeds</i>) yang kompetitif memperebutkan air dan nutrisi, sehingga butuh deteksi berdasarkan bentuk daunnya.	Citra resolusi tinggi dari gulma berdaun lebar dan padi.	Membandingkan algoritma klasifikasi <i>Support Vector Machine</i> (SVM), <i>Minimum Distance</i> , dan <i>Parallelepiped</i> .	SVM secara konsisten menjadi model terbaik dengan akurasi klasifikasi melampaui 99% dalam mendeteksi dan memisahkan kelas gulma <i>broadleaf</i> .	Jurnal ini relevan dengan tujuan metode saya, yaitu memisahkan tanaman berdasarkan morfologinya. Jurnal ini memperkuat argumen bahwa algoritma SVM memiliki akurasi yang sangat tinggi dalam membedakan bentuk fisik daun.

		Rosle & Muhammad Huzaifah Mohd Roslim [16]					
3	<i>Smart agriculture: utilizing machine learning and deep learning for drought stress identification in crops (2024)</i>	Tariq Ali, Saif Ur Rehman, Shamshair Ali, Khalid Mahmood, Silvia Aparicio Obregon, Rubén Calderón Iglesias, Tahir Khurshaid & Imran Ashraf [17]	Kekeringan (<i>drought stress</i>) mengganggu fungsi fisiologis tanaman. Sehingga dibutuhkan sistem otomasi AI untuk mengidentifikasi tingkat stres dan ketahanan air pada tanaman.	4.030 data observasi terkait respons protein dan fisikokimia tanaman akibat kekeringan.	Model ML konvensional seperti SVM dan <i>Gradient Boosting</i> .	Algoritma SVM terbukti dapat mendeteksi profil kekeringan pada tanaman dengan akurasi klasifikasi 82%.	Jurnal ini berkaitan langsung dengan teori botani di latar belakang mengenai kapasitas menahan air dan adaptasi terhadap stres air. Jurnal ini membuktikan bahwa SVM dapat digunakan untuk membaca kondisi fisik tanaman dalam hubungannya dengan toleransi kekeringan.
4	<i>Automated machine learning based plant stress detection system (2021)</i>	Karthick manoj R., Sasilatha T. & Padmapriya J. [18]	Identifikasi kesehatan tanaman secara manual oleh manusia memiliki keterbatasan dan kurang presisi,	3.000 citra daun dari <i>database</i> publik (Kaggle).	<i>Pre-processing</i> dan segmentasi, mengekstrak fitur tekstur, lalu menggunakan SVM untuk	Sistem otomasi menghasilkan tingkat akurasi klasifikasi sebesar 99,6% menggunakan SVM.	Jurnal ini menunjukkan bagaimana proses segmentasi di depan SVM, sehingga berfungsi untuk mengatasi latar belakang visual yang kompleks seperti

			sehingga berujung pada penanganan yang salah.		mengklasifikasi hasil.		yang ada di latar belakang saya.
5	<i>A Review of Machine Learning Approaches in Plant Leaf Disease Detection and Classification</i> (2021)	Majji V Applalana idu & G. Kumaravelan [19]	Merupakan studi komprehensif untuk mengevaluasi algoritma ML (seperti SVM dan KNN) mana yang paling cocok dalam mengekstrak fitur visual daun (ukuran, bentuk, tekstur, warna).	Berbagai literatur yang menggunakan ratusan hingga ribuan citra daun dengan kondisi pencahayaan dan variasi.	<i>Review</i> terhadap berbagai metode segmentasi, ekstraksi fitur (bentuk dan tekstur), serta algoritma klasifikasi.	Menyimpulkan bahwa SVM adalah pengklasifikasi yang sangat andal dan umum digunakan dalam memproses data ekstraksi fitur manual, dengan akurasi rata-rata di atas 95% untuk berbagai jenis daun.	Jurnal ulasan ini merupakan bukti yang memperkuat bahwa SVM dan KNN dapat membedakan antar spesies tanaman dengan akurasi yang tinggi. Selain itu, jurnal ini menyatakan bahwa algoritma mesin dapat diatur untuk fokus mengekstrak informasi visual spesifik.

4.2 Metode

Metode yang digunakan pada tahapan ini adalah kombinasi antara algoritma *Support Vector Machine* (SVM) sebagai pengklasifikasi (*classifier*) biner dan metode *Histogram of Oriented Gradients* (HOG) sebagai ekstraktor fitur bentuk berbasis gradien lokal.

4.3 Workflow

Proses klasifikasi citra sukulen menggunakan metode SVM+HOG dijalankan melalui lima tahapan utama, yaitu:

- Standarisasi Citra

Citra *input* yang memiliki ukuran beragam diseragamkan dimensinya menjadi 224x224 piksel. Setelah itu, citra RGB dikonversi ke format

Grayscale untuk menghilangkan informasi warna yang bias dan memfokuskan algoritma pada intensitas gradien tepi.

- Ekstraksi Fitur HOG

Citra *grayscale* dibagi menjadi beberapa piksel dan blok sel. Algoritma kemudian menghitung arah kemiringan tepi (*gradient orientation*) pada setiap area dan mengompilasinya menjadi histogram representasi fitur bentuk satu dimensi.

- *Data Splitting*

Vektor fitur hasil HOG kemudian dipisah menggunakan rasio 80:20, di mana 80% (320 citra) dialokasikan sebagai data latih dan 20% (80 citra) sebagai data uji.

- Pelatihan Model (*Training*)

Vektor fitur dari data latih diumpankan ke dalam algoritma SVM.

- Evaluasi

Model dievaluasi menggunakan metrik *Confusion Matrix* dan *Learning Curve*.

4.4 Parameter Model

Pelatihan model dilakukan menggunakan algoritma *Support Vector Machine* (SVM) terhadap vektor fitur bentuk daun yang telah diekstrak menggunakan metode HOG. Untuk mencapai performa yang optimal dan menghindari *overfitting*, pelatihan dilakukan melalui tiga skenario percobaan (*hyperparameter tuning*). Parameter yang dimodifikasi meliputi fungsi kernel (Linear dan RBF) serta parameter regularisasi (C), sementara parameter toleransi (1e-3) dan iterasi maksimal (-1) dikunci sebagai variabel kontrol.

Tabel 4.2 Parameter Model SVM HOG saat UTS

index	Percobaan	Kernel	Parameter C	Gamma	Strategi Multi-class	Akurasi	Error Rate (Loss)
0	1	linear	0.05	scale	ovo	68.75%	0.3125
1	2	linear	0.1	scale	ovo	72.50%	0.2750
2	3	rbf	0.5	scale	ovo	70.00%	0.3000

Berdasarkan tabel di atas, percobaan ke-2 menghasilkan performa terbaik dengan tingkat akurasi mencapai 72.50% dan *error rate* terendah sebesar 0.2750.

Keberhasilan dan stabilitas model pada percobaan ini dijelaskan melalui pemilihan konfigurasi *hyperparameter* berikut ini.

1) Fungsi Kernel (*Linear*)

Penggunaan Kernel *Linear* terbukti lebih efektif dibandingkan Kernel RBF pada kasus ini. Hal ini dikarenakan ukuran matriks sel pada ekstraksi fitur HOG telah diperbesar untuk menyederhanakan fitur dan mengurangi kerumitan detail *noise*. Hal ini akan membuat *decision boundary* antara pola Daun Runcing dan Daun Bulat menjadi lebih sederhana sehingga dapat dipisahkan secara optimal hanya dengan garis lurus tanpa perlu dipetakan ke dimensi yang lebih tinggi.

2) Parameter Regularisasi / C (0.1):

Parameter C berfungsi untuk mengontrol bagaimana algoritma menghukum kesalahan klasifikasi selama proses pelatihan. Nilai C sebesar 0.1 terbukti paling ideal. Nilai 0.1 memberikan *margin* yang lebih lebar dan fleksibel, sehingga model tidak terlalu kaku dalam menghafal setiap titik data latih.

3) Parameter Gamma ('*scale*')

Parameter Gamma menentukan seberapa jauh jangkauan pengaruh dari satu titik data sampel terhadap pembentukan garis pemisah. Dengan menggunakan argumen '*scale*', sistem secara otomatis menghitung dan menyesuaikan nilai Gamma yang paling proporsional berdasarkan jumlah fitur visual HOG dan varians penyebaran data citra sukulen yang ada.


4) Strategi Multikelas / OVO (*One-vs-One*)

Meskipun klasifikasi morfologi daun sukulen hanya terdiri dari 2 kelas, pengaturan *One-vs-One* (OVO) ditetapkan sebagai standar konfigurasi komputasi komprehensif pada algoritma SVM. Pada klasifikasi dua kelas, arsitektur OVO bekerja dengan efisien karena algoritma hanya perlu membangun satu ruang komputasi untuk langsung membandingkan kelas 0 (Daun Runcing) dengan kelas 1 (Daun Bulat).

4.5 Hasil Evaluasi

4.6.1 Evaluasi Model Terbaik

Model terbaik dari percobaan ke-2 dievaluasi kinerjanya menggunakan metrik *Confusion Matrix* terhadap 80 data uji (40 Daun Runcing dan 40 Daun Bulat).



Gambar 4.1 *Confusion Matrix* SVM HOG saat UTS

Berdasarkan *classification report* yang dihasilkan dari pengujian, diperoleh rincian metrik evaluasi, yaitu:

1) *Precision*

Model memperoleh nilai *percision* 0.71 (71%) untuk kelas Daun Runcing dan 0.74 (74%) untuk kelas Daun Bulat. Hal ini menunjukkan bahwa dari keseluruhan tebakan model terhadap masing-masing kelas, tingkat kebenarannya baik dan model tidak sering salah melabeli daun bulat sebagai daun runcing, ataupun sebaliknya.

2) *Recall*


Model mencatatkan nilai *recall* 0.75 (75%) untuk Daun Runcing dan 0.70 (70%) untuk Daun Bulat. Hal ini membuktikan kemampuan model cukup baik dalam menemukan dan mendeteksi daun yang sebenarnya dari total populasi data uji.

3) *F1-Score*

Nilai rata-rata harmonis antara *precision* dan *recall* berada di angka 0.73 untuk Daun Runcing dan 0.72 untuk Daun Bulat. Angka yang seimbang ini menyatakan bahwa model berkinerja secara stabil dan tidak mengalami bias terhadap salah satu kelas.

4.6.2 Analisis *Overfitting*

Overfitting digunakan untuk memastikan bahwa algoritma *machine learning* belajar mengenali pola dan tidak hanya menghafal data latih. Pada analisis ini, digunakan metode evaluasi *learning curve* (kurva pembelajaran). *Learning curve* adalah alat yang merepresentasikan proses pembelajaran secara matematis yang terjadi saat suatu tugas diulang. Dalam pembelajaran mesin statistik, *learning curve* merupakan grafik garis yang memetakan proses pembelajaran (pada sumbu y) terhadap pengalaman atau waktu (pada sumbu x) [20].



Gambar 4.2 *Learning Curve* SVM HOG saat UTS

Berdasarkan gambar tersebut, hasil evaluasi menunjukkan kurva yang ideal untuk model pengklasifikasi dengan *dataset* berskala kecil, di mana pada fase awal (saat jumlah data latih di bawah 100 sampel), terlihat jarak (*gap*) yang cukup lebar antara garis merah (akurasi *training*) dan garis hijau (akurasi *testing*), yang mengindikasikan kecenderungan awal model untuk menghafal data (*high variance*). Seiring dengan bertambahnya jumlah data latih, kurva garis merah secara konsisten menurun untuk melakukan penyesuaian, sementara kurva garis hijau terus mengalami peningkatan. Pada akhir observasi, kedua garis tersebut bergerak saling mendekat dan stabil pada selisih akurasi yang rasional. Konvergensi kurva ini menjadi bukti visual matematis bahwa penyesuaian *hyperparameter*

(Kernel Linear, $C=0.1$) telah berhasil menyelamatkan model dari *overfitting*. Model terbukti benar-benar mempelajari generalisasi pola ekstraksi fitur HOG, bukan sekadar melakukan memorisasi terhadap data latih, sehingga tangguh saat dihadapkan pada citra daun sukulen yang baru.

4.6 Kelebihan dan Kelemahan Metode

4.7.1 Kelebihan

1) Efisiensi Komputasi Tinggi

Proses pelatihan model SVM+HOG pada perangkat keras (*hardware*) lokal beroperasi dengan cepat. Model ini tidak menuntut unit pemrosesan GPU yang berat, karena komputasi hanya dilakukan terhadap matriks vektor fitur 1 dimensi hasil rangkuman HOG [21].

2) Optimal untuk Masalah Biner

Algoritma SVM memiliki landasan matematis yang kuat untuk memecahkan masalah klasifikasi dua kelas melalui pencarian margin maksimal secara rasional [15] [22], sehingga sangat cocok untuk memisahkan fitur daun bersudut tajam dengan daun bertekstur kurva halus.

4.7.2 Kelemahan

1) Ketergantungan Ekstraksi Manual

Tidak seperti *deep learning* yang secara otomatis mempelajari fitur tanpa intervensi manual [7], metode tradisional seperti HOG mengharuskan pengguna untuk menentukan sendiri parameter ukuran jendela (*window*), sel (*cell*), dan blok secara *trial-and-error* [15].

2) Rentan terhadap *Noise* Latar Belakang

Algoritma SVM tidak bekerja dengan baik jika dihadapkan pada kumpulan data yang mengandung *noise* [23]. Karena algoritma HOG membagi *seluruh* area gambar menjadi sel-sel kecil untuk dihitung orientasi gradiennya [21], maka jika pemotongan (*cropping*) tidak bersih, latar belakang gambar yang padat dan kompleks (seperti tanah atau pot) akan ikut terekam sebagai fitur, sehingga dapat menyesatkan model SVM [24].

BAB V

PENGEMBANGAN *DEEP LEARNING*

5.1 Kajian Jurnal Terkait

Tabel 5.1 Kajian Jurnal Terkait Metode *Deep Learning*

No	Judul	Penulis	Masalah	Dataset	Metode	Hasil	Keterkaitan dengan Penelitian
1	<i>Enhancing Succulent Plant Species Classification : A MobileNetV3-Large Approach</i> (2024)	Wahyu Dhermawan, Susilawati, Muhathir, Rizki Muliono, Andre Hasudungan Lubis, Nurul Khairina [9]	Klasifikasi spesies sukulen masih kurang eksploratif, dan ukuran daun tanaman yang kecil membutuhkan model yang ringan namun akurat.	Dataset Sukulen (10 Kelas)	CNN (MobileNetV3-Large)	Evaluasi model menunjukkan performa akurasi yang tinggi (92% - 99%) untuk klasifikasi tanaman.	Relevan karena membahas langsung objek studi (sukulen). Memvalidasi penggunaan MobileNet sebagai arsitektur yang cocok untuk morfologi tanaman berukuran kecil.
2	<i>Small Sample Succulent Image Classification Based on Transfer Learning</i> (2024)	Yu Wen, Shu-Ping Zhang, Miao Huang, Zhihua Hu, Lili Tao [25]	Tidak adanya dataset publik skala besar untuk sukulen, sehingga model konvensional sulit menangkap fitur global dari jumlah data yang kecil.	Dataset Sukulen Mandiri (31 spesies)	<i>Transfer Learning</i> , membandingkan MobileViT, MobileNetV2, ResNet50, dan VGG.	MobileViT berhasil mengungguli seluruh model CNN pembanding dalam menangani klasifikasi gambar sukulen bersampel kecil (<i>small-sample</i>), dengan	Relevan karena membahas penanganan klasifikasi daun sukulen pada kondisi data terbatas. Menjadi rujukan untuk evaluasi berbagai arsitektur (MobileNet & ResNet).

						mencetak rekor akurasi tertinggi di angka 96.90%.	
3	<i>PSR-LeafNet: A Deep Learning Framework for Identifying Medicinal Plant Leaves Using Support Vector Machines</i> (2024)	Praveen Kumar Sekharam antry, Marada Srinivasa Rao, Yarramalle Srinivas & Archana Uriti [26]	Pengenalan tanaman melalui bentuk/morfologi daun sulit dilakukan karena perubahan umur daun dan gangguan orientasi gambar.	<i>Flavia Dataset, MalayaKew Leaf, Indian Medicinal Plants</i>	Hibrida CNN (PSR-LeafNet) untuk ekstraksi fitur + klasifikasi SVM.	Akurasi klasifikasi mencapai 95.88% pada <i>dataset</i> Flavia dengan metrik presisi 94.40%.	Relevan karena membuktikan bahwa penggunaan CNN sebagai ekstraktor fitur yang diklasifikasikan oleh SVM sangat baik untuk menangkap fitur bentuk dan tekstur daun.
4	<i>A CNN-SVM study based on selected deep features for grapevine leaves classification</i> (2022)	Murat Koklu, M. Fahri Unlersen, Ilker Ali Ozkan, M. Fatih Aslan, Kadir Sabanci [12]	Spesies daun (<i>grapevine</i>) memiliki morfologi visual yang sangat mirip satu sama lain (sulit dibedakan dengan mata telanjang).	<i>Grapevine Leaves Image Dataset</i> (5 spesies, 2.500 gambar)	<i>Pre-trained</i> MobileNetV2 (Ekstraksi Fitur) + SVM.	Akurasi MobileNetV2 tunggal (97.20%), namun kombinasi CNN-SVM berhasil mencapai akurasi tertinggi 97.60%.	Relevan karena mengonfirmasi bahwa ekstraksi fitur (seperti fungsi HOG) dari arsitektur MobileNet yang kemudian dimasukkan ke klasifikator SVM dapat meningkatkan akurasi secara signifikan pada morfologi daun yang mirip.

5	<i>SVM and KNN Based CNN Architectures for Plant Classification</i> (2022)	Sukanta Ghosh ¹ , Amar Singh, Kavita, N. Z. Jhanjhi, Mehedi Masud & Sultan Aljahdali [24]	Tingginya kemiripan variasi morfologi daun (ukuran, tekstur, bentuk geometri, urat daun) antar spesies tanaman yang berbeda.	LeafSnap, Flavia, <i>MalayaKew Dataset</i>	CNN + <i>Support Vector Machine</i> (SVM).	Kinerja model CNN+SVM mencapai 98.5% pada <i>dataset</i> Flavia dan 96.3% pada LeafSnap.	Relevan sebagai rujukan yang menyatakan bahwa fitur morfologi daun (<i>shape & venation</i>) paling optimal diolah dengan arsitektur hibrida <i>machine learning</i> seperti CNN+SVM.
6	<i>A VGG-19 Model with Transfer Learning and Image Segmentation for Classification of Tomato Leaf Disease</i> (2022)	Thanh-Hai Nguyen, Thanh-Nghia Nguyen & Ba-Viet Ngo [13]	Daun memiliki area latar belakang (<i>background</i>) yang mengganggu proses ekstraksi fitur visual yang halus.	<i>Tomato Leaf Disease Dataset</i>	Pra-pemrosesan (Segmentasi Gambar) + CNN (VGG-19).	VGG-19 menunjukkan efektivitas tinggi dalam mengenali pola spasial setelah citra daun disegmentasi.	Relevan untuk menunjukkan bahwa arsitektur VGG-19 sangat kuat memproses ekstraksi bentuk (<i>shape</i>) jika dipadukan dengan teknik segmentasi visual (sejalan dengan fungsi HOG yang fokus pada tepi).
7	<i>Tomato leaf diseases recognition based on deep convolutional neural networks</i> (2023)	Kai Tian, Jiefeng Zeng, Tianci Song, Zhuliu Li, Asenso Evans,	Diperlukan analisis komputasi untuk melihat kedalaman <i>layer</i> mana yang paling optimal untuk mengenali	PlantVillage (18.160 gambar daun)	Komparasi model dalam (<i>Deep</i>): VGG16, Inception, ResNet50.	VGG16 meraih akurasi 99.62%-99.75%, sedangkan ResNet50 meraih 98.92%-99.50%.	Relevan karena membandingkan langsung antara performa VGG16 dan ResNet50 dalam mengenali citra daun.

		Jiuhao Li [27]	detail visual citra daun.				
8	<i>Origin Identification of Saposhnikovia divaricata by CNN Embedded with the Hierarchical Residual Connection Block (2023)</i>	Dongming Li, Chenglin Yang, Rui Yao & Li Ma [28]	Klasifikasi manual berdasarkan ciri fenotipik (fisik/morfologi) memakan waktu lama, sehingga membutuhkan model yang dapat melihat "fitur multiskala".	2.001 gambar tanaman <i>Saposhnikovia divaricata</i>	ResNet50, ResNet50, Res2Net50.	Dalam uji komparasi ResNet50 hanya meraih (86.68%), Res2Net50 (88.68%), ResNet50 (89.38%), ConvNext_T (91.83%), dan RepVggNet_B0 (92.18%). Namun, dengan IResNet, akurasi menjadi 93.72%	Relevan karena terdapat penggunaan ResNet. Membahas bagaimana koneksi residual (<i>residual blocks</i>) pada ResNet membantu jaringan menangkap detail fenotipik/morfologi fisik tanaman untuk klasifikasi yang presisi.

5.2 Model

1) CNN

Pada tahap *machine learning* awal, klasifikasi morfologi daun sukulen menggunakan ekstraksi fitur HOG (*Histogram of Oriented Gradients*) yang digabungkan dengan pengklasifikasi SVM. Meskipun HOG sangat baik dalam menangkap informasi tepi (*edges*) dan gradien bentuk daun, metode ini memerlukan rekayasa fitur secara manual (*manual feature engineering*) [24]. Oleh karena itu, pada tahap pengembangan *deep learning*, digunakan arsitektur berbasis *Convolutional Neural Network* (CNN). CNN dapat mengotomatisasi ekstraksi fitur spasial, tekstur, dan bentuk daun secara berlapis tanpa perlu campur tangan manual, sehingga dapat mengatasi kelemahan model klasik ketika menghadapi variasi morfologi daun yang sangat mirip antar spesies [12] [24].

2) MobileNetV2

MobileNet digunakan sebagai model komparasi kinerja (*benchmarking*). MobileNet dipilih karena karakteristik morfologi daun sukulen sering kali berukuran kecil dan sampel datanya terbatas di dunia nyata [25]. MobileNet menggunakan operasi *depthwise separable convolution* yang secara drastis memangkas jumlah parameter dan beban komputasi [6] [9] [25]. Perbandingan ini penting untuk melihat apakah model yang sangat ringan mampu menyaingi akurasi model berat seperti VGG-16 dalam kasus klasifikasi sukulen *small-sample*.


3) VGG16

Arsitektur VGG-16 dipilih sebagai model *deep learning* utama dalam penelitian ini karena karakteristik strukturalnya yang sangat linier dengan logika ekstraksi fitur HOG. VGG-16 menggunakan filter konvolusi berukuran kecil (3x3) yang ditumpuk secara mendalam [29]. Tumpukan filter kecil ini secara matematis mirip dengan cara HOG mendeteksi orientasi gradien tepi pada piksel [24] [30]. Keunggulan VGG-16 adalah kemampuannya dalam membedah piksel gambar menjadi pola-pola halus secara jauh lebih kaya dibandingkan ekstraksi manual [13] [31]. Namun, model ini mengorbankan waktu komputasi untuk mendapatkan akurasi peta fitur (*feature map*) yang sangat padat dan mendalam [19].

4) ResNet50

ResNet (seperti ResNet-50) digunakan sebagai pembanding model untuk mengatasi masalah *vanishing gradient* yang mungkin dialami oleh jaringan konvolusi sekuensial biasa [6]. Dengan memanfaatkan blok koneksi residual (*shortcut connections*), ResNet memungkinkan model mempelajari fitur morfologi tanaman sukulen dari berbagai skala tanpa mengalami penurunan performa saat jaringan semakin dalam [28]. Hal ini relevan untuk membedakan spesies sukulen yang secara kasat mata tampak identik tetapi memiliki perbedaan fenotipik mikroskopis.

5.3 Arsitektur Jaringan



Gambar 4.1 Arsitektur Jaringan pada *Deep Learning*

Diagram alur di atas memvisualisasikan arsitektur umum jaringan saraf tiruan yang diterapkan pada penelitian ini. Citra masukan berdimensi 224x224x3 awalnya melalui tahap *rescaling* (normalisasi piksel). Selanjutnya, matriks gambar diekstraksi fitur visualnya (seperti garis, tekstur, hingga bentuk) oleh blok konvolusi (*Base Model*). Lapisan ekstraksi fitur disesuaikan bergantung pada model yang digunakan, di mana *Flatten* digunakan untuk CNN Klasik dan VGG16 untuk mempertahankan koordinat spasial, sementara *Global Average Pooling* (GAP) digunakan pada ResNet50 dan MobileNetV2. Fitur yang telah diekstraksi kemudian diproses oleh *Hidden Dense Layer* berkapasitas 64 hingga 128 neuron dengan fungsi aktivasi ReLU dan diamankan dari *overfitting* melalui *Dropout Layer*. Lalu diakhiri oleh *Output Layer* berskalar tunggal dengan fungsi aktivasi Sigmoid untuk menentukan probabilitas klasifikasi.

5.4 Skenario Pelatihan dan *Hyperparameter*

Fungsi aktivasi yang digunakan pada *hidden layer* untuk seluruh arsitektur *deep learning* adalah ReLU (*Rectified Linear Unit*), sedangkan *output layer* menggunakan fungsi aktivasi Sigmoid untuk mengakomodasi klasifikasi biner. Seluruh proses komputasi pelatihan dirancang untuk berjalan secara iteratif hingga batas maksimal 200 epoch. Untuk mengoptimalkan kinerja dan mencegah *overfitting*, dalam hal ini diterapkan sistem *callback* secara dinamis, yaitu *Early Stopping* untuk menghentikan pelatihan saat akurasi validasi stagnan dan *ModelCheckpoint* untuk mengeksport bobot (*weights*) model secara spesifik pada titik ekuilibrium terbaiknya.

Adapun rincian eksplorasi *hyperparameter* untuk masing-masing model, yaitu:

1) CNN Klasik (*Sequential*)

Pada arsitektur *from scratch* ini, pengujian difokuskan pada perbandingan algoritma optimisasi adaptif (Adam) dan probabilistik (SGD). Rentang *learning rate* (LR) yang diuji berada pada skala 0.01 hingga 0.0001, dengan

variasi ukuran batch 32 dan 64. Nilai pemutusan neuron pada lapisan *Dropout* diuji pada rentang 0.2 hingga 0.4.

Konfigurasi terbaik adalah *Optimizer* Adam, *Learning Rate* 0.0001, *Batch Size* 32, dan *Dropout* 0.3.

2) MobileNetV2 (*Transfer Learning*)

Sebagai model yang memiliki arsitektur komputasi ringan, iterasi parameter fokus pada variasi *batch size* (32 dan 64) untuk mengukur kecepatan pemrosesan fitur. Dalam hal ini, *Optimizer* diuji antara Adam dan SGD, dengan rentang LR 0.001 hingga 0.0001, dan persentase *Dropout* antara 0.2 hingga 0.5.

Konfigurasi terbaik adalah *Optimizer* Adam, *Learning Rate* 0.001, *Batch Size* 64, dan *Dropout* 0.2.

3) VGG16 (*Transfer Learning*)

VGG16 memiliki bobot parameter matriks yang sangat besar, sehingga modifikasi ditekankan pada variasi *Dropout* yang cukup tinggi (0.3 hingga 0.5) untuk mencegah adanya *overfitting* yang agresif. *Learning rate* dieksplorasi secara sangat halus pada skala 0.001, 0.0001, hingga 0.00001 dengan *Optimizer* Adam dan SGD.

Konfigurasi terbaik adalah *Optimizer* Adam, *Learning Rate* 0.0001 dan *Dropout* 0.3.

4) ResNet50 (*Transfer Learning*)

Arsitektur dalam berlapis koneksi residual ini diuji menggunakan variasi *Optimizer* Adam dan RMSprop. Nilai *learning rate* disesuaikan di angka makro yang sangat kecil (0.0001, 0.0002, dan 0.00007). Tingkat *Dropout* dieksplorasi secara bertahap dari 0.3, 0.4, hingga 0.5 untuk mengatasi potensi bias bobot bawaan (*pre-trained weights*).

Konfigurasi terbaik adalah *Optimizer* Adam, *Learning Rate* 0.0001 dan *Dropout* 0.5.

5) Arsitektur Hybrid (CNN + SVM)

Pada skenario ini, lapisan ekstraksi CNN berjalan statis, sementara *hyperparameter* difokuskan pada penyesuaian fungsi kernel ruang dimensi mesin vektor pendukung (SVM). Fungsi kernel yang diuji meliputi Linear,

RBF dan Polynomial, dengan penalti toleransi *error* (C) sebesar 1.0 dan 10.0, serta nilai gamma berskala otomatis (*scale*).

Konfigurasi terbaik adalah Kernel Linear, Nilai C = 1.0 dan Gamma = *Scale*.

5.5 Hasil dan Evaluasi

Berdasarkan serangkaian skenario pelatihan (*training*) dan pengujian (*testing*) yang telah dieksekusi, model-model *deep learning* menunjukkan tingkat performa yang sangat bervariasi dalam membedakan kelas morfologi daun sukulen. Berdasarkan hasil evaluasi menggunakan data uji murni (*testing dataset*), diperoleh kinerja sebagai berikut.

1) VGG16

Mencapai akurasi *testing* tertinggi sebesar 93.00% (Model ini merupakan model terbaik secara keseluruhan).

2) MobileNetV2

Mencapai akurasi *testing* sebesar 91.00%.

3) CNN + SVM (Hybrid)

Mencapai akurasi *testing* sebesar 87.00%.

4) CNN Klasik (Sequential)

Mencapai akurasi *testing* sebesar 82.74%.

5) ResNet50: Mencatat performa terendah dengan akurasi *testing* sebesar 57.00%.

Secara keseluruhan, pemanfaatan arsitektur *Transfer Learning* dengan modifikasi lapisan *Flatten* (seperti pada VGG16) terbukti paling baik dalam memetakan fitur geometri daun dibandingkan metode lainnya.

5.6 Kelebihan dan Kelemahan Model

1) CNN

Keunggulan utama CNN dibandingkan *machine learning* konvensional adalah kemampuannya untuk mengotomatisasi ekstraksi fitur. CNN menghilangkan kebutuhan rekayasa fitur secara manual (*manual feature engineering*) karena lapisan konvolusi dan *pooling*-nya secara mandiri menangkap informasi bermakna dari data mentah selama proses pelatihan [31]. CNN klasik memiliki kelemahan utama yaitu sangat bergantung pada jumlah data yang besar (*data-hungry*), memakan waktu pelatihan yang lama

dan membutuhkan komputasi perangkat keras tingkat tinggi (seperti GPU) [32].

2) MobileNetV2

MobileNet memiliki keunggulan mutlak dalam hal efisiensi dan keringanan model (*lightweight*). Dengan menggunakan operasi *depthwise separable convolution*, MobileNet secara signifikan memangkas jumlah parameter dan beban komputasi [25]. Kelebihan lainnya, model ini terbukti memiliki ketahanan performa yang sangat baik bahkan ketika dilatih menggunakan dataset dengan sampel kecil (*small-sample datasets*) [25]. Meskipun ringan dan efisien, pemangkasan parameter yang drastis pada MobileNet dapat mengurangi kedalaman representasi fitur jika dibandingkan dengan model yang sangat besar [9].

3) VGG16

Keutamaan arsitektur VGG terletak pada kedalaman (*depth*) dan kepadatan ekstraksi fiturnya. Dengan menggunakan blok konvolusi yang ketat berisi filter berukuran 3x3, VGG sangat ahli dalam menangkap detail-detail spasial yang sangat halus, seperti pola urat, tepian, dan bercak pada morfologi daun. Model ini menghasilkan tingkat pengenalan dan akurasi yang sangat tinggi [13]. Kelemahan terbesar VGG adalah tingginya beban komputasi (*computationally expensive*) [19]. Karena VGG-16 memiliki sekitar 138 juta parameter, ukuran model ini sangat besar, proses pelatihannya memakan waktu yang sangat lama, dan sangat sulit untuk diaplikasikan langsung pada sistem atau perangkat bersumber daya rendah (*low resource systems*) [19].

4) ResNet50


Keutamaan ResNet adalah dapat memecahkan salah satu masalah terbesar dalam jaringan saraf tiruan yang sangat dalam, yaitu masalah gradien menghilang (*vanishing gradient*) dan degradasi akurasi [8]. Hal ini dicapai dengan memperkenalkan blok koneksi residual (*shortcut/skip connections*), yang memungkinkan model mempelajari fitur multiskala secara lebih baik dan mempertahankan performa meskipun lapisannya terus ditambah [8]. Kelemahan dari ResNet adalah kompleksitas arsitekturnya yang

menyebabkan beberapa *layer* di dalam jaringan yang terlalu dalam berpotensi tidak mempelajari apapun secara signifikan [19].

BAB VI

WORKFLOW

6.1 Diagram *Workflow*



Gambar 6.1 Diagram Alur Kerja

6.2 Tahapan *Workflow*

6.2.1 Pengumpulan *Dataset*

Tahap awal penelitian dimulai dengan mengumpulkan data mentah berupa citra digital tanaman sukulen. Total data yang berhasil dikumpulkan adalah sebanyak 3.100 file gambar yang terbagi secara seimbang ke dalam dua kelas morfologi utama, yaitu kelas daun_bulat dan kelas daun_runcing. Pengumpulan data ini menjadi fondasi utama bagi seluruh proses pelatihan model biner.

6.2.2 *Preprocessing Data*

Sebelum dimasukkan ke dalam arsitektur jaringan saraf, seluruh citra mentah wajib melalui serangkaian manipulasi terstruktur (*preprocessing*) untuk menyamakan persepsi komputasi komputer, yaitu:

1) *Resizing*

Mengubah dimensi spasial seluruh gambar secara seragam menjadi ukuran 224 x 224 piksel.

2) Normalisasi (*Rescaling*)

Mengonversi nilai kecerahan piksel asli (skala 0–255) menjadi representasi matriks bernilai pecahan (0 hingga 1 atau -1 hingga 1) untuk mempercepat konvergensi gradien.

3) Augmentasi Data

Menerapkan transformasi acak seperti rotasi, pergeseran (*shifting*), dan pembalikan (*flipping*) untuk memperkaya variasi sampel visual daun.

4) *Data Splitting*

Membagi *dataset* ke dalam tiga partisi independen menggunakan kontrol acak (*random seed*), dengan rasio pembagian 80% untuk data latih (*training*), 10% untuk data validasi (*validation*) dan 10% untuk data uji (*testing*).

6.2.3 Penerapan Metode *Machine Learning*

Tahap ini mewakili pendekatan pembelajaran mesin tradisional (*baseline model*). Gambar diproses menggunakan algoritma *Histogram of Oriented Gradients* (HOG) untuk mengekstrak vektor gradien tepi daun secara manual (*hand-crafted features*). Hasil ekstraksi fitur HOG ini kemudian diumpankan ke dalam model pengklasifikasi *Support Vector Machine* (SVM) dengan melakukan

tuning pada fungsi *kernel* (Linear, RBF, dan Polynomial) untuk mencari batas pemisah keputusan kelas terbaik.

6.2.4 Penerapan Metode *Deep Learning*

Tahap ini merupakan tahapan utama, di mana komputer dilatih untuk mengenali ciri-ciri gambar daun secara otomatis tanpa perlu diatur manual oleh manusia. Eksperimen dilakukan dengan membandingkan dua pendekatan utama, yaitu membangun model CNN Klasik dan menggunakan metode *Transfer Learning* (VGG16, MobileNetV2, dan ResNet50). Metode *Transfer Learning* memanfaatkan model yang telah memiliki pengetahuan dasar karena sebelumnya telah dilatih menggunakan jutaan gambar umum (*ImageNet*). Selain itu, dikembangkan pula model gabungan (hibrida CNN + SVM). Pada model gabungan ini, CNN bertugas sebagai pengekstraksi untuk merangkum gambar daun menjadi kumpulan angka penting, lalu angka-angka tersebut diserahkan kepada algoritma SVM untuk diputuskan apakah gambar tersebut masuk ke kelas daun bulat atau daun runcing.

6.2.5 Evaluasi Model

Setiap model yang telah selesai dilatih langsung dievaluasi tingkat generalisasinya menggunakan data uji murni yang diisolasi dan dirahasiakan selama proses pelatihan. Kriteria penilaian tidak hanya bertumpu pada nilai akurasi umum, melainkan dibedah secara kritis menggunakan metrik pengujian biner komprehensif, seperti skor presisi (*Precision*), sensitivitas (*Recall*), ekuilibrium performa (*F1-Score*), serta visualisasi pemetaan kesalahan melalui matriks kebingungan (*Confusion Matrix*).

6.2.6 Perbandingan Hasil dan Kesimpulan Model Terbaik

Tahap akhir dari alur penelitian ini adalah melakukan proses *benchmarking* atau menjejerkan seluruh performa final dari kelima arsitektur yang diuji. Melalui perbandingan metrik evaluasi tersebut, ditarik sebuah kesimpulan ilmiah mengenai model mana yang paling unggul dalam mengenali geometri daun sukulen secara akurat. Model terbaik yang terpilih (VGG16 dengan akurasi pengujian sebesar 93.00%) kemudian diekspor bobot finalnya untuk diintegrasikan ke dalam tahap demonstrasi program menggunakan antarmuka berbasis web *Streamlit*.

BAB VII

HASIL DAN EVALUASI MODEL

7.1 Metriks Evaluasi

Kinerja setiap model yang diusulkan dievaluasi secara komprehensif menggunakan *confusion matrix* pada data pengujian murni (*testing dataset*). Dari matriks tersebut, terdapat:

1. Akurasi (*Accuracy*)

Rasio total prediksi benar (daun bulat dan runcing) terhadap keseluruhan *dataset*.

2. Presisi (*Precision*)

Tingkat ketepatan model saat menebak sebuah kelas tertentu.

3. Sensitivitas (*Recall*)

Kemampuan model mengenali seluruh sampel positif pada kelas tertentu.

4. *F1-Score*

Nilai harmonis yang menyeimbangkan *Precision* dan *Recall*, sangat berguna untuk melihat stabilitas performa secara keseluruhan.

7.2 Hasil Model *Machine Learning*

Pengujian pada metode pembelajaran mesin klasik memanfaatkan ekstraksi fitur manual HOG yang diumpankan pada algoritma *Support Vector Machine* (SVM). Dari pencarian parameter terbaik, model SVM Kernel Polynomial (C=1.0, Gamma=Scale) memberikan performa tertinggi dengan tingkat akurasi pengujian mencapai **83.39%** (berhasil mengungguli Kernel Linear di 71.94% dan Kernel RBF di 81.77%).

7.3 Hasil Model *Deep Learning*

- 1) CNN Klasik

Model buatan sendiri ini diuji menggunakan variasi *optimizer*, *learning rate*, *batch size*, dan tingkat *dropout*. Konfigurasi dengan *optimizer* Adam dan ukuran pemotongan neuron menengah memberikan hasil terbaik.

Tabel 7.1 Hasil Model CNN Klasik

Skenario	<i>Optimizer</i>	<i>Learning Rate</i>	<i>Batch Size</i>	<i>Dropout</i>	Akurasi
----------	------------------	----------------------	-------------------	----------------	---------

1	Adam	0.001	32	0.2	71.94%
2	SGD	0.01	64	0.4	73.55%
3	Adam	0.0001	32	0.3	82.00%

Model terbaik (Skenario 3) mampu mencapai akurasi pengujian sebesar 82.00%. Rata-rata bobot harmonis menunjukkan model cukup seimbang, dengan *F1-Score* sebesar 0.81 untuk daun bulat dan 0.83 untuk daun runcing.

2) MobileNet50

Sebagai arsitektur ringan, MobileNetV2 dievaluasi untuk melihat efisiensinya. Penyesuaian ukuran *batch* dan *dropout* memberikan dampak signifikan terhadap performa model.

Tabel 7.2 Hasil Model MobileNet50

Skenario	<i>Optimizer</i>	<i>Learning Rate</i>	<i>Batch Size</i>	<i>Dropout</i>	Akurasi
1	Adam	0.0001	32	0.2	87.00%
2	Adam	0.001	32	0.5	87.67%
3	Adam	0.001	64	0.2	91.00%
4	SGD	0.001	32	0.2	74.00%

MobileNetV2 mencatatkan hasil yang impresif pada Skenario 3 dengan akurasi akhir mencapai 91.00%. Model ini sangat stabil dengan tingkat Presisi dan *Recall* rata-rata berada di atas angka 0.90 untuk kedua kelas.

3) VGG16

Model ini menggunakan arsitektur linear yang sangat sensitif terhadap nilai *learning rate*. Pengurangan nilai *dropout* secara proporsional terbukti dapat menaikkan akurasi akhir.

Tabel 7.3 Hasil Model VGG16

Skenario	<i>Optimizer</i>	<i>Learning Rate</i>	<i>Dropout</i>	Akurasi
1	Adam	0.0001	0.5	89.69%
2	Adam	0.0001	0.3	93.00%
3	Adam	0.00001	0.5	85.31%
4	SGD	0.001	0.4	80.62%

Arsitektur VGG16 (Skenario 2) merupakan peringkat performa tertinggi dengan akurasi pengujian menembus 93.00%. Model menunjukkan keseimbangan prediksi yang sangat kuat, yaitu mencatat nilai presisi 0.93 untuk daun bulat dan 0.93 untuk daun runcing.

4) ResNet50

Model berarsitektur dalam (*deep residual network*) ini diuji secara ketat pada angka *learning rate* makro yang sangat kecil untuk mencegah lonjakan gradien.

Tabel 7.4 Hasil Model ResNet50

Skenario	<i>Optimizer</i>	<i>Learning Rate</i>	<i>Dropout</i>	Akurasi
1	Adam	0.0001	0.5	53.33%
2	Adam	0.0002	0.5	53.12%
3	Adam	0.00007	0.4	53.44%
4	RMSprop	0.0001	0.3	57.50%

Model ini mengalami kegagalan generalisasi yang signifikan. Meskipun konfigurasi terbaik sempat mencapai 60.62% pada fase validasi, akurasi pengujian jatuh ke angka 53.33%. *Recall* untuk kelas daun bulat hanya mencapai 0.26, menandakan model ini nyaris kehilangan kemampuan mendeteksi geometri lengkungan daun secara utuh akibat efek *Global Average Pooling*.

5) CNN + SVM

Untuk mengatasi kelemahan ekstraksi fitur manual pada algoritma klasik, digunakan model fusi di mana CNN bertindak sebagai ekstraktor fitur spasial secara otomatis dan SVM sebagai pengklasifikasi. Parameter fungsi *kernel* diuji untuk mencari *margin* pembatas terbaik.

Tabel 7.5 Hasil Model CNN SVM

Skenario	Fungsi Kernel	<i>Parameter C</i>	<i>Gamma</i>	Akurasi
1	RBF	1.0	Scale	86.00%
2	Linear	1.0	Scale	87.00%
3	RBF	10.0	Scale	87.00%


Hasil skenario optimal diperoleh menggunakan Skenario 2 (Kernel Linear, $C=1.0$) yang menghasilkan akurasi pengujian sebesar 87.00%. Kombinasi ini terbukti lebih baik dibandingkan metode SVM dengan HOG secara mandiri (83.39%) maupun CNN Klasik secara mandiri (82.00%). Hal ini membuktikan bahwa representasi fitur konvolusi memberikan batasan margin keputusan spasial yang jauh lebih tegas dan terstruktur bagi mesin SVM.

BAB VIII

VISUALISASI HASIL

8.1 Grafik Kurva Pembelajaran (*Learning Curve*) Model Terbaik

Visualisasi ini difokuskan pada model *Transfer Learning* VGG16 sebagai arsitektur yang menghasilkan performa tertinggi.




Gambar 8.1 *Learning Curve* Model VGG16

Pergerakan kurva validasi yang fluktuatif serta lonjakan tajam *Validation Loss* di akhir *epoch* menunjukkan bahwa model VGG16 mengalami fenomena *overfitting* ekstrem pada fase-fase akhir pelatihan. Hal ini disebabkan oleh kapasitas parameter VGG16 yang sangat besar (mencapai lebih dari 14 juta parameter), sehingga dengan cepat menghafal detail piksel dari *dataset* sukulen yang berskala moderat.

Meskipun demikian, tingginya akurasi pengujian (*testing accuracy*) yang mencapai **93.00%** pada data uji murni membuktikan bahwa performa generalisasi model ini tetap terjaga secara optimal. Keberhasilan ini didukung oleh penerapan mekanisme *callback* *ModelCheckpoint* dengan konfigurasi `save_best_only=True`. Melalui sistem ini, arsitektur berhasil mengeksport dan mengunci bobot (*weights*) terbaik model pada pertengahan *epoch*, yaitu tepat sebelum titik *Validation Loss* mengalami lonjakan naik, sehingga file model `.keras` yang digunakan pada tahap akhir adalah representasi model pada kondisi paling baik.

8.2 *Confusion Matrix* Keseluruhan Model


- 1) SVM + HOG



Gambar 8.2 *Confusion Matrix* Model SVM HOG

Pada metode *machine learning* klasik ini, dari total 620 data uji yang diekstraksi, model berhasil memprediksi 255 daun bulat dan 262 daun runcing secara tepat. Namun, matriks ini mulai memperlihatkan batasan dari metode rekayasa fitur manual. Terdapat total 103 gambar yang mengalami misklasifikasi (55 ditebak salah sebagai runcing, dan 48 ditebak salah sebagai bulat). Hal ini menandakan bahwa kalkulasi gradien manual (HOG) terkadang kesulitan membedakan batas tepi daun jika terdapat kemiripan latar belakang atau pencahayaan piksel.


2) CNN



Gambar 8.3 *Confusion Matrix* Model CNN Klasik

Matriks dibangun secara mandiri (*from scratch*) ini menampilkan kemampuan klasifikasi *baseline* yang cukup baik, di mana model dapat mengenali daun runcing (131 tebakan benar), namun mengalami sedikit kesulitan (*struggle*) dalam mengenali kelas daun bulat. Hal ini terlihat dari 37 citra daun bulat yang justru salah diklasifikasikan sebagai daun runcing. Kondisi ini wajar terjadi pada CNN yang tidak memanfaatkan bobot pengetahuan sebelumnya (*pre-trained weights*).


3) MobileNetV2



Gambar 8.4 *Confusion Matrix* Model MobileNetV2

MobileNetV2 menunjukkan performa klasifikasi yang baik dengan total 273 tebakan benar dari 300 data uji. Secara rinci, model berhasil mengklasifikasikan 145 citra daun bulat dan 128 citra daun runcing secara akurat. Meskipun terdapat sedikit kecenderungan salah tebak pada kelas daun runcing (di mana 18 citra daun runcing salah diklasifikasikan sebagai daun bulat), secara keseluruhan matriks ini mengonfirmasi bahwa operasi *depthwise separable convolution* pada MobileNetV2 efisien dan dapat mempertahankan presisi tinggi tanpa membebani memori komputasi.


4) VGG16



Gambar 8.5 *Confusion Matrix* Model VGG16

VGG16 merupakan performa terbaik dengan tebakan pada diagonal utama yang sangat dominan. Dari total 300 data uji, model ini berhasil mengklasifikasikan secara tepat 128 citra daun bulat dan 151 citra daun runcing. Tingkat kesalahan (*misclassification*) sangat minim, di mana model hanya salah menebak 12 daun bulat sebagai daun runcing dan 9 daun runcing sebagai daun bulat. Hal ini membuktikan bahwa lapisan *Flatten* pada arsitektur VGG16 berhasil mempertahankan koordinat spasial lengkungan dan sudut tajam daun dengan presisi tinggi.


5) ResNet50



Gambar 8.6 *Confusion Matrix* Model ResNet50

Visualisasi matriks pada ResNet50 menampilkan ketidakseimbangan prediksi yang ekstrem (*extreme bias*). Model berhasil menebak 123 daun runcing, namun gagal total dalam mendeteksi daun bulat. Dari 141 citra daun bulat, model salah menebak 104 citra sebagai daun runcing (hanya 37 yang ditebak benar). Bukti empiris ini memperkuat hipotesis bahwa arsitektur perataan global (*Global Average Pooling*) pada ResNet50 merusak nilai piksel lengkungan daun, sehingga model kebingungan dan cenderung asal menebak semuanya sebagai daun runcing.


6) CNN + SVM



Gambar 8.7 *Confusion Matrix* Model CNN SVM

Matriks pada arsitektur hibrida ini menunjukkan margin keputusan yang stabil dan seimbang, di mana model berhasil mengenali 129 daun bulat dan 132 daun runcing dengan benar. Kesalahan terdistribusi secara nyaris simetris (19 positif palsu dan 20 negatif palsu). Hal ini mengonfirmasi bahwa ekstraksi fitur otomatis menggunakan konvolusi CNN dapat memberikan parameter numerik yang sangat terstruktur, sehingga algoritma klasifikasi SVM dapat menarik garis batas pemisah (*decision boundary*) dengan optimal.

8.3 Grafik Perbandingan Performa Keseluruhan



Gambar 8.8 Grafik Perbandingan Akurasi Keseluruhan Model Klasifikasi

Diagram batang di atas memvisualisasikan hierarki performa akhir dari keenam arsitektur model yang dievaluasi. VGG16 tampil sangat dominan sebagai model terbaik dengan akurasi tertinggi mencapai 93.00%, disusul oleh arsitektur komputasi ringan MobileNetV2 (91.00%). Grafik ini juga membuktikan bahwa pendekatan fusi fitur otomatis (CNN + SVM di 87.00%) berhasil melampaui kemampuan model *Machine Learning* berfitur manual (SVM HOG) maupun CNN sekuensial dasar. Sebaliknya, ResNet50 mencatatkan akurasi terendah (53.33%), mengonfirmasi bahwa arsitektur berskala sangat dalam dengan sistem *Global Average Pooling* justru merusak retensi informasi fitur spasial pada kasus pengenalan bentuk daun.

BAB IX

PEMBAHASAN

9.1 Analisis Performa Model Terbaik

Berdasarkan serangkaian pengujian yang telah dilakukan terhadap data uji (*testing dataset*), arsitektur *Transfer Learning* VGG16 berhasil ditetapkan sebagai model terbaik dalam studi kasus ini dengan pencapaian akurasi tertinggi sebesar 93.00%. Keunggulan signifikan yang ditunjukkan oleh VGG16 ini secara teknis dilandasi oleh perpaduan optimal antara *Convolutional Layer* bawaan (*base model*) dan penggunaan lapisan Flatten pada bagian klasifikasi akhir (*head classifier*) [23]. Proses ekstraksi melalui *Convolutional Layer* bawaan VGG16 terbukti sangat krusial dalam mempertahankan letak titik koordinat spasial piksel, kontur kurva, dan orientasi sudut tepian citra [23]. Lapisan konvolusi ini memanfaatkan struktur spasial dari matriks gambar untuk mendeteksi tepian (*edges*) lokal secara hierarkis, yang merupakan fitur pembeda utama (*key visual cues*) untuk memisahkan morfologi antara daun sukulen berbentuk bulat dan runcing [23] [30].

Selanjutnya, untuk mengolah peta fitur (*feature map*) berukuran 7x7x512 yang dihasilkan oleh blok konvolusi tersebut, arsitektur ini menggunakan lapisan *Flatten* [13]. Berbeda dengan metode *Global Average Pooling* (GAP) yang merata-rata dan melarutkan detail spasial piksel [7], proses transformasi melalui lapisan *Flatten* mempertahankan seluruh jumlah nilai angkanya (kuantitas numerik parameter) [7] [33]. Vektor linear ini kemudian diumpankan ke dalam *Fully Connected Layer* agar model dapat melakukan kalkulasi probabilitas klasifikasi secara presisi [7] [24]. Ketepatan arsitektur ini dibuktikan secara empiris melalui visualisasi *Confusion Matrix*, di mana dari total 300 data uji, VGG16 menunjukkan eror prediksi yang sangat minim, yaitu hanya keliru mengenali 12 citra daun bulat dan 9 citra daun runcing.

9.2 Komparasi *Machine Learning* Konvensional dan *Deep Learning*

Pengujian ini memberikan gambaran yang jelas mengenai perbedaan kemampuan generalisasi antara paradigma *machine learning* tradisional berbasis rekayasa fitur manual (*hand-crafted features*) dengan arsitektur *deep learning* berbasis pengekstraksian fitur otonom.

1) Keterbatasan Fitur Manual (HOG + SVM)

Algoritma SVM dengan ekstraksi fitur HOG (menggunakan Kernel Polynomial) hanya mampu menembus akurasi 83.39%. Kelemahan utama pendekatan ini terletak pada kekakuan kalkulasi matriks gradien orientasi tepi HOG yang sangat sensitif terhadap variasi pencahayaan latar belakang dan pergeseran posisi objek [23]. Ketika dihadapkan pada daun bulat yang memiliki intensitas bayangan tajam di tepinya, algoritma HOG sering kali salah untuk menangkapnya sebagai sudut lancip, sehingga memicu terjadinya misklasifikasi pada data uji.

2) Keunggulan Ekstraksi Otomatis (*Deep Learning*)

Sebaliknya, model-model *Deep Learning* dapat mengekstraksi representasi visual daun sukulen secara berlapis mulai dari pola makro (warna dan tekstur) hingga mikro (lekukan tepi). Superioritas ini terlihat jelas pada performa MobileNetV2 (91.00%) yang membuktikan bahwa meskipun berarsitektur ringan dengan operasi *depthwise separable convolution*, model ini baik dalam menangani keterbatasan jumlah sampel (*small-sample dataset*) melalui transfer pengetahuan bobot *pre-trained* ImageNet [6].

3) Validasi Model Hibrida (CNN + SVM)

Keunggulan fitur *Deep Learning* diperkuat oleh keberhasilan model fusi CNN + SVM (87.00%). Dengan memotong lapisan klasifikasi akhir CNN Klasik dan mengalihkan fungsinya murni sebagai pengekstraksi fitur otomatis, vektor angka yang dihasilkan terbukti memiliki pemisahan ruang linear yang jauh lebih tegas. Hal ini memungkinkan algoritma SVM Kernel Linear menarik garis batas keputusan (*decision boundary*) dengan *margin* yang lebih optimal dibandingkan saat disandingkan dengan fitur HOG manual.

9.3 Kendala Eksperimen dan Analisis Kelemahan Model

Selama jalannya penelitian, ditemukan beberapa kendala teknis yang menjadi kelemahan dari masing-masing arsitektur, yaitu:

1. Fenomena *Overfitting* Ekstrem pada Model Besar

Kendala utama yang diidentifikasi pada model terbaik (VGG16) adalah timbulnya grafik pembelajaran (*Learning Curve*) yang sangat tidak stabil,

ditandai dengan lonjakan tajam nilai *Validation Loss* di akhir-akhir *epoch*. Hal ini terjadi karena kapasitas parameter VGG16 terlalu masif (lebih dari 14 juta parameter) untuk ukuran dataset sukulen yang moderat. Akibatnya, pada fase akhir pelatihan, jaringan saraf tidak lagi memahami bentuk daun melainkan beralih menghafal mati posisi piksel data latih. Ketidakseimbangan ini berhasil dimitigasi berkat penerapan fungsi *callback* *ModelCheckpoint* yang mengisolasi bobot model pada titik kepintaran tertingginya sebelum *overfitting* itu meledak.

2. Kegagalan Total ResNet50 akibat *Global Average Pooling* (GAP)

Kelemahan paling fatal terjadi pada ResNet50 yang mencatatkan akurasi terendah, yaitu hanya sebesar 53.33%. Nilai ini merepresentasikan kegagalan generalisasi total karena performanya setara dengan tebakan acak (probabilitas 50:50). Berdasarkan analisis arsitektur, kehancuran ini disebabkan oleh penggunaan lapisan *Global Average Pooling* (GAP) pada ujung ResNet50. Berbeda dengan *Flatten*, GAP merata-rata seluruh nilai matriks spasial menjadi skalar tunggal. Pada kasus klasifikasi daun sukulen yang sangat bertumpu pada detail lokasi sudut lancip atau lengkungan tepi, proses perataan GAP justru melarutkan dan membuang informasi koordinat penting tersebut karena tertutup oleh dominasi piksel warna hijau dari latar daun. Akibatnya, model mengalami bias ekstrem dan salah menebak data.

3. Keterbatasan Citra pada CNN Klasik

Model CNN Klasik *Sequential* tertahan di akurasi 82.00% dan cenderung mengalami bias. Hal ini menunjukkan bahwa jaringan konvolusi buatan sendiri yang dangkal masih kesulitan membangun pemahaman fitur abstrak yang kuat tanpa bantuan bobot terlatih dari *dataset* skala raksasa.

9.4 Peluang Pengembangan ke Depan

Untuk mengatasi kendala keterbatasan data serta kelemahan arsitektur yang ditemukan dalam penelitian ini, terdapat beberapa peluang pengembangan yang dapat diimplementasikan pada studi lanjutan, yaitu:

1. Ekspansi dan Sintesis *Dataset*

Masalah *overfitting* akibat kapasitas model yang terlalu besar dapat diatasi di masa mendatang dengan memperluas jumlah sampel data, baik melalui

penambahan variasi augmentasi geometris yang lebih agresif maupun pemanfaatan teknologi *Generative Adversarial Networks* (GAN) untuk memproduksi citra daun sukulen sintetis yang realistis.

2. Pengembangan Hierarki Klasifikasi Spesies (Multi-Class Classification)

Saat ini, batasan penelitian masih berfokus pada klasifikasi biner berdasarkan morfologi daun (bulat vs runcing). Ke depannya, anotasi *dataset* dapat diperluas menggunakan label taksonomi spesifik sehingga model dapat ditingkatkan untuk menebak dan mengklasifikasikan spesies tanaman sukulen secara presisi (seperti membedakan antara spesies *Echeveria*, *Haworthia*, *Sedum*, atau *Aloe*). Transisi menuju klasifikasi multi-kelas ini akan sangat meningkatkan nilai guna praktis aplikasi bagi ahli botani maupun penghobi tanaman hias.

3. Eksplorasi *Fine-Tuning* Bertahap

Dibandingkan mengunci seluruh bobot *base model*, penelitian selanjutnya dapat menerapkan teknik *Fine-Tuning* parsial dengan membuka kunci beberapa blok konvolusi teratas secara bertahap menggunakan *learning rate* yang sangat kecil, guna menyelaraskan bobot ImageNet dengan karakteristik lokal tanaman sukulen.

4. Penerapan Arsitektur Berbasis *Attention*

Mengingat klasifikasi morfologi ini sensitif terhadap detail lokasional ujung daun, eksplorasi arsitektur modern seperti *Vision Transformers* (ViT) atau penambahan lapisan *Attention Mechanism* (seperti SE-Block) sangat direkomendasikan. Mekanisme ini akan memaksa model memberikan bobot perhatian komputasi yang lebih tinggi pada area ujung dan tepian daun, sehingga dapat menghindari eror pembuangan fitur seperti yang dialami oleh lapisan *Global Average Pooling* pada ResNet50.

BAB X

DEMO PROGRAM

10.1 Bahasa Pemrograman dan *Library* yang Digunakan

Aplikasi ini dibangun menggunakan bahasa pemrograman Python 3.10. Adapun *library* utama yang digunakan dalam proses *deployment* adalah:

1) Streamlit

Framework utama untuk membangun antarmuka web interaktif secara instan.

2) TensorFlow / Keras

Digunakan untuk memuat (*loading*) file model .keras dan mengeksekusi komputasi prediksi.

3) Pillow (PIL) & NumPy

Digunakan untuk membaca *file* gambar yang diunggah pengguna dan memanipulasinya ke dalam bentuk matriks (*array*).

10.2 Cara Menjalankan Program


Untuk menjalankan aplikasi secara lokal (*localhost*), tahapan yang harus dilakukan, yaitu:

1. Menyiapkan direktori proyek yang berisi *file* kode app.py, *file* model model_vgg16_terbaik.keras, dan *file* requirements.txt.
2. Membuka terminal atau *command prompt* (CMD) pada direktori tersebut.
3. Menginstal seluruh dependensi dengan menjalankan perintah: pip install -r requirements.txt
4. Menjalankan *server* Streamlit dengan perintah: streamlit run app.py
5. Aplikasi akan otomatis terbuka pada penjelajah web (*browser*) di alamat URL: http://localhost:8501.

10.3 Tampilan Hasil Program


Proses pengujian program pada Streamlit ini secara otomatis melibatkan tahap *background processing*. Gambar apa pun yang diunggah sebagai *input* oleh pengguna akan diseragamkan ukurannya (*resize*) menjadi dimensi spasial 224x224 piksel untuk memenuhi standar matriks masukan arsitektur VGG16. Matriks warna pada gambar tidak dibagi secara manual di tahap ini (dipertahankan pada rentang

0-255), melainkan diserahkan langsung kepada *pipeline preprocessing* bawaan yang telah terintegrasi di dalam bobot model.



Gambar 10.1 Halaman Utama Program


Gambar di atas menunjukkan antarmuka awal aplikasi berbasis web yang telah dikustomisasi secara visual menggunakan manipulasi CSS. Pada halaman ini, pengguna disediakan area interaktif bergaris putus-putus (*drag and drop box*) untuk mengunggah satu buah file citra digital berekstensi .jpg, .jpeg, atau .png.



Gambar 10.2 Proses *Input* dan *Output* dari Program

Gambar di atas mendemonstrasikan proses fungsionalitas aplikasi. Sebagai contoh *input*, diunggah citra daun sukulen tak terlihat (*unseen data*) yang memiliki bentuk ujung menumpul. Meskipun citra tersebut memiliki variasi latar belakang yang kompleks (terdapat objek hewan), setelah tombol dieksekusi, model dapat mengabaikan gangguan visual tersebut dan berfokus mengekstrak fitur tanaman. Sistem berhasil mengeluarkan *output* prediksi secara tepat sebagai Daun Bulat,

lengkap dengan tingkat keyakinan probabilitas (*confidence score*) yang sangat tinggi, yaitu mencapai 99.91%.



Gambar 10.3 Proses *Input* dan *Output* dari Program

Berdasarkan hasil eksekusi pada gambar di atas, sistem menghasilkan *output* prediksi berupa kelas Daun Runcing dengan tingkat keyakinan (*confidence score*) yang sangat tinggi, yaitu mencapai 90.61%. Fenomena ini secara teoritis tidak mencerminkan kegagalan fungsi model, namun merupakan sebuah pembuktian konkret terhadap konsep *Closed-World Assumption* pada sistem klasifikasi biner berbasis jaringan saraf konvolusi (*Convolutional Neural Network*).

Secara matematis, model biner yang dikonfigurasi menggunakan lapisan *output* tunggal berskala aktivasi Sigmoid hanya dilatih untuk memetakan probabilitas

biner secara mutlak, yaitu antara nilai 0 (mewakili Daun Bulat) atau nilai 1 (mewakili Daun Runcing). Model tidak memiliki kapasitas kesadaran untuk mengenali entitas di luar domain tersebut, seperti manusia atau kendaraan.

Ketika citra interior mobil diproses, lapisan konvolusi (*Convolutional Layer*) pada arsitektur VGG16 melakukan ekstraksi fitur terhadap matriks gambar dan mendeteksi dominasi elemen geometris berupa garis lurus yang kaku, kisi-kisi ventilasi AC yang berkotak tajam, serta sudut-sudut tegas pada panel instrumen *dashboard*. Di dalam memori bobot (*weights*) VGG16, karakteristik gradien tepi dan deteksi sudut tajam tersebut memiliki kemiripan orientasi spasial yang sangat intensif dengan representasi fitur kelas "Daun Runcing" dibandingkan pola kurva halus tak bersudut pada kelas "Daun Bulat". Akibatnya, operasi perkalian matriks secara deterministik mengarahkan nilai probabilitas mendekati angka 1, sehingga menghasilkan prediksi "Daun Runcing" dengan skor keyakinan 90.61%. Kasus uji ini memberikan justifikasi ilmiah penting bahwa model beroperasi murni berdasarkan interpretasi kalkulasi pola geometris numerik piksel, bukan berdasarkan pemahaman visual biologis.

BAB XI

KESIMPULAN

5.1 Kesimpulan

Berdasarkan serangkaian tahapan penelitian yang telah dilakukan untuk memecahkan masalah tantangan identifikasi visual morfologi daun sukulen akibat tingginya tingkat kemiripan bentuk, dapat ditarik kesimpulan sebagai berikut.

- Penerapan Metode dan Akurasi *Machine Learning*

Untuk mengukur tingkat akurasi konvensional, metode ekstraksi fitur *Histogram of Oriented Gradients* (HOG) yang dikombinasikan dengan algoritma pengklasifikasi *Support Vector Machine* (SVM) terbukti efektif. Ekstraksi fitur HOG mampu menangkap karakteristik visual dan informasi tepi (*edge*) daun dengan baik. Melalui pengujian parameter, model SVM Kernel *Polynomial* ($C=1.0$) memberikan performa *Machine Learning* tertinggi dengan tingkat akurasi pengujian mencapai 83.39% dalam membedakan kelas Daun Bulat dan Daun Runcing.

- Perbandingan Kinerja *Machine Learning* vs. *Deep Learning*

Dalam mengevaluasi dan membandingkan performa secara kuantitatif, paradigma *deep learning* terbukti secara umum lebih superior dibandingkan *machine learning* konvensional. Model-model *deep learning* dapat mengekstraksi representasi visual daun sukulen secara otonom dan berlapis, sehingga lebih kebal terhadap variasi pencahayaan dibandingkan metode rekayasa manual HOG yang cenderung sensitif terhadap *noise* dan latar belakang.

- Optimalisasi dan Model Terbaik

Melalui serangkaian pengujian *hyperparameter*, arsitektur *Transfer Learning* VGG16 ditetapkan sebagai model terbaik dalam studi kasus ini. VGG16 menunjukkan hasil yang sangat dominan dengan mencetak akurasi pengujian tertinggi sebesar 93.00%. Kemampuan unggul ini disusul oleh model berarsitektur ringan MobileNetV2 (91.00%), model fusi CNN+SVM (87.00%), dan CNN Klasik (82.00%). Di sisi lain, ResNet50 mengalami kegagalan generalisasi dengan akurasi terendah (53.33%) akibat

penggunaan *Global Average Pooling* (GAP) yang merusak retensi detail koordinat spasial pada ujung daun.

5.2 Saran Pengembangan

Untuk mengatasi beberapa kendala teknis dan menyempurnakan kelemahan arsitektur dalam penelitian ini, terdapat beberapa peluang pengembangan untuk studi lanjutan, yaitu:

- Ekspansi dan Sintesis *Dataset*
Untuk mencegah fenomena *overfitting* yang sempat terjadi pada model berkapasitas besar (seperti VGG16), sampel data perlu diperluas menggunakan augmentasi yang lebih agresif atau memanfaatkan teknologi *Generative Adversarial Networks* (GAN) untuk memproduksi citra sukulen sintetis.
- Pengembangan Hierarki Klasifikasi Multi-Kelas
Memperluas anotasi dari sekadar pembagian morfologi biner menuju pendeteksi spesies yang lebih spesifik (seperti membedakan spesies *Echeveria*, *Haworthia*, *Sedum*, atau *Aloe*) untuk meningkatkan nilai praktis aplikasi.
- Eksplorasi *Fine-Tuning* Bertahap
Menerapkan pembukaan kunci blok konvolusi terbatas dari *base model* secara bertahap guna menyelaraskan bobot bawaan *ImageNet* dengan karakteristik geometri tanaman sukulen secara lebih presisi.
- Penerapan Arsitektur Berbasis *Attention*
Mengeksplorasi arsitektur mutakhir seperti *Vision Transformers* (ViT) atau menambahkan lapisan *Attention Mechanism* yang dirancang untuk memberikan fokus komputasi lebih tinggi secara khusus pada area ujung lekukan daun.

DAFTAR PUSTAKA

- [1] Y. N. Gunariyati, W. Andajani, T. D. Sutiknjo and A. D. Pamujiati, "Manajemen Strategi Pengembangan Usaha Tanaman Hias Sukulen di Desa Rembang, Kecamatan Ngadiluwih, Kabupaten Kediri," *Jurnal Ilmiah Pertanian Nasional (JINTAN)*, 2023.
- [2] E. Elbasi, A. E. Topcu, E. Cina, A. I. Zreikat, A. Shdefat, C. Zaki and W. Abdelbaki, "Enhanced Plant Leaf Classification over a Large Number of Classes Using Machine Learning," *Applied Sciences (Appl. Sci.)*, 2024.
- [3] N. S. Bhelkar and S. Bolavarapu, "Machine Learning Techniques for Medicinal Plants Identification Using Leaf Features: Review," *Frontiers in Health Informatics*, 2024.
- [4] A. Leverett, S. Hartzell, K. Winter, M. Garcia, J. Aranda, A. Virgo, A. Smith, P. Focht, A. Rasmussen-Arda, W. G. T. Willats, D. Cowan-Turner and A. M. Borland, "Dissecting succulence: Crassulacean acid metabolism and hydraulic capacitance are independent adaptations in *Clusia* leaves," *Plant, Cell & Environment*, 2023.
- [5] G. Mozzi, A. Crivellaro, D. E. Blasini, M. Vásquez-Cruz, T. Hernández-Hernández and K. R. Hultine, "Divergent structural leaf trait spectra in succulent versus non-succulent plant taxa," *Annals of Botany*, 2024.
- [6] J. Yao, S. N. G. S. Tran and S. Sawyer, "Deep Learning for Plant Identification and Disease Classification from Leaf Images: Multi-prediction Approaches," *ACM*, 2024.
- [7] S. E. M., D. A. Chandy, S. P. M. and A. Poullose, "A Hybrid Deep Learning Model for Aromatic and Medicinal A Hybrid Deep Learning Model for Aromatic and Medicinal," *AgriEngineering*, 2025.
- [8] A. Nasiri, M. Omid, A. Taheri-Garavand and A. Jafari, "Deep learning-based precision agriculture through weed recognition in sugar beet fields," *Sustainable Computing: Informatics and Systems*, vol. 35, 2022.

- [9] W. Dhermawan, Susilawati, Muhathir, R. Muliono, A. H. Lubis and N. Khairina, "Enhancing Succulent Plant Species Classification: A MobileNetV3-Large Approach," in *2024 International Conference on Information Technology Research and Innovation (ICITRI)*, 2024.
- [10] S. Kavitha, T. S. Kumar, E. Naresh, V. H. Kalmani, K. D. Bamane and P. K. Pareek, "Medicinal Plant Identification in Real-Time Using Deep Learning Model," *SN Computer Science*, 2023.
- [11] X. Tong, Z. Liang and F. Liu, "Succulent Plant Image Classification Based on Lightweight GoogLeNet with CBAM Attention Mechanism," *applied sciences*, 2025.
- [12] M. Koklu, M. F. Unlersen, I. A. Ozkan, M. F. Aslan and K. Sabanci, "A CNN-SVM study based on selected deep features for grapevine leaves classification," *Measurement*, 2022.
- [13] T.-H. Nguyen, T.-N. Nguyen and B.-V. Ngo, "A VGG-19 Model with Transfer Learning and Image Segmentation for Classification of Tomato Leaf Disease," *AgriEngineering*, 2022.
- [14] P. Kaur, S. Harnal, R. Tiwari, S. Upadhyay, S. Bhatia and A. Mashat, "Recognition of Leaf Disease Using Hybrid Convolutional Neural Network by Applying Feature Reduction," *sensors*, 2022.
- [15] D. Venkataraman and M. N, "Support Vector Machine Based Classification of Medicinal Plants Using Leaf Features," in *IEEE*, 2017.
- [16] N. Sulaiman, N. Che'Ya, A. Juraimi, N. Noor, R. Rosle and M. Mohd Roslim, "Assessment of three broadleaf weed species classification in rice field using UAV hyperspectral imaging and machine learning," *Frontiers in Plant Science*, vol. 16, 2025.
- [17] T. Ali, S. U. Rehman, S. Ali, K. Mahmood, S. A. Obregon, R. C. Iglesias, T. Khurshaid and I. Ashraf, "Smart agriculture: utilizing machine learning and deep learning for drought stress identification in crops," *Scientific Reports*, 2024.
- [18] K. R., S. T. and P. J., "Automated machine learning based plant stress detection system," *Materials Today: Proceedings*, 2021.

- [19] I. Proceedings of the Third International Conference on Intelligent Communication Technologies and Virtual Mobile Networks, "A Review of Machine Learning Approaches in Plant Leaf Disease Detection and Classification," 2021.
- [20] O. A. M. López, A. M. López and J. Crossa, Overfitting, Model Tuning, and Evaluation of Prediction Performance, Springer, 2022.
- [21] M. Saher, M. Alsaedi and A. A. Ibraheemi, "Automated Grading System for Breast Cancer Histopathological Images Using Histogram of Oriented Gradients (HOG) Algorithm," *Applied Data Science and Analysis*, pp. 78-87, 2023.
- [22] D. Valkenborg, A.-J. Rousseau, M. Geubbelmans and T. Burzykowski, "Support vector machines," *STATISTICS AND RESEARCH DESIGN*, pp. 754-757, 2023.
- [23] O. A. M. López, A. M. López and J. Crossa, Multivariate Statistical Machine Learning Methods for Genomic Prediction, Springer Nature, 2022.
- [24] S. Ghosh, A. Singh, Kavita, N. Z. Jhanjhi, M. Masud and S. Aljahdali, "SVM and KNN Based CNN Architectures for Plant Classification," *Tech Science Press*, vol. 71, 2022.
- [25] Y. Wen, S.-P. Zhang, M. Huang, Z. Hu and L. Tao, "Small Sample Succulent Image Classification Based on Transfer Learning," in *CACML '24: Proceedings of the 2024 3rd Asia Conference on Algorithms, Computing and Machine Learning*, Shanghai, 2024.
- [26] P. K. Sekharamanthy, M. S. Rao, Y. Sriniva and A. Uriti, "PSR-LeafNet: A Deep Learning Framework for Identifying Medicinal Plant Leaves Using Support Vector Machines," *Big Data and Cognitive Computing*, 2024.
- [27] K. Tian, J. Zeng, T. Song, Z. Li, A. Evans and J. Li, "Tomato leaf diseases recognition based on deep convolutional neural networks," *Journal of Agricultural Engineering 2023*;, 2023.
- [28] D. Li, C. Yang, R. Yao and L. Ma, "Origin Identification of *Saposhnikovia divaricata* by CNN Embedded with the Hierarchical Residual Connection Block," *agronomy*, 2023.

- [29] I. Kunduracioglu and I. Pacal, "Deep Learning-Based Disease Detection in Sugarcane Leaves: Evaluating EfficientNet Models," *Journal of Operations Intelligence*, vol. 2, no. 1, 2024.
- [30] M. U. Ahmad, S. Ashiq, G. Badshah, A. H. Khan and M. Hussain, "Feature Extraction of Plant Leaf Using Deep Learning," *Complexity*, 2022.
- [31] K. M. Ang, W. H. Lim, S. S. Tiang, A. Sharma, M. M. Eid, S. M. Tawfeek, D. S. Khafaga, A. H. Alharbi and A. A. Abdelhamid, "Optimizing Image Classification: Automated Deep Learning Architecture Crafting with Network and Learning Hyperparameter Tuning," *biomimetics*, 2023.
- [32] A. K. Mulugeta, D. P. Sharma and A. H. Mesfin, "Deep learning for medicinal plant species classification and recognition: a systematic review," *Frontiers in Plant Science*, 2023.
- [33] W. Hussain, M. F. Mushtaq, M. Shahroz, U. Akram, E. S. Ghith, M. Tlija, T.-h. Kim and I. Ashraf, "Ensemble genetic and CNN model-based image classification by enhancing hyperparameter tuning," *Scientific Reports*, 2025.
- [34] N. M., V. M. S., P. B S and G. H. Kumar, "Leaf Classification based on GLCM Texture and SVM," *International Journal of Computer Applications*, 2020.

LAMPIRAN


Tautan GitHub

<https://github.com/Noviana21/sukulen-new/tree/main>

Tautan *Dataset*

https://drive.google.com/drive/folders/1yKRZIU5ROe3XHU_Tei8M0ycNfZe76o_kc?usp=sharing

Screenshot Program



Klasifikasi Morfologi Daun Sukulen

Silakan seret dan lepas (*drag and drop*) atau pilih satu gambar daun sukulen untuk memprediksi karakteristik morfologinya menggunakan arsitektur VGG16.

Unggah File Gambar Sukulen (Maksimal 1 Gambar)

 bulatdankucing.jpeg +
1.0MB



Gambar Sukulen yang Siap Dievaluasi

 *Tips: Anda dapat mengganti gambar kapan saja dengan mengklik ikon silang (X) pada kotak upload di atas atau langsung menyeret gambar baru.*

Mulai Prediksi Bentuk Daun

 Analisis Selesai! Model mengidentifikasi objek sebagai: **Daun Bulat**

Tingkat Keyakinan Klasifikasi (Confidence Score)

99.91%

Klasifikasi Morfologi Daun Sukulen

Silakan seret dan lepas (*drag and drop*) atau pilih satu gambar daun sukulen untuk memprediksi karakteristik morfologinya menggunakan arsitektur VGG16.

Unggah File Gambar Sukulen (Maksimal 1 Gambar)



Gambar Sukulen yang Siap Dievaluasi

 *Tips: Anda dapat mengganti gambar kapan saja dengan mengklik ikon silang (X) pada kotak upload di atas atau langsung menyeret gambar baru.*

Mulai Prediksi Bentuk Daun

 **Analisis Selesai!** Model mengidentifikasi objek sebagai: **Daun Runcing**

Tingkat Keyakinan Klasifikasi (Confidence Score)

90.61%

Potongan Kode VGG16

```
from tensorflow.keras.applications import VGG16
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Flatten, Dense, Dropout

# Memuat Base Model VGG16 tanpa lapisan klasifikasi teratas
(include_top=False)
base_model_vgg = VGG16(weights='imagenet', include_top=False,
input_shape=(224, 224, 3))
base_model_vgg.trainable = False # Mengunci bobot konvolusi

# Membangun Arsitektur Klasifikasi Biner
model_vgg = Sequential([
    base_model_vgg,
    Flatten(), # Membongkar matriks fitur spasial menjadi vektor
1D
    Dense(128, activation='relu'),
    Dropout(0.3), # Regularisasi untuk mencegah overfitting
    Dense(1, activation='sigmoid') # Output biner (Daun Bulat /
Daun Runcing)
])

model_vgg.compile(optimizer=Adam(learning_rate=0.0001),
                  loss='binary_crossentropy',
                  metrics=['accuracy'])
```

Hasil Evaluasi Tambahan

1) Log Evaluasi SVM + HOG

Pencarian parameter difokuskan pada pengujian variasi fungsi kernel dan parameter penalti (C).

- Skenario 1: Kernel Linear, C=10.0, Gamma=Scale (Akurasi Latih: 92.06% | Akurasi Uji: 71.94%)
- Skenario 2: Kernel RBF, C=1.0, Gamma=Scale (Akurasi Latih: 94.60% | Akurasi Uji: 81.77%)
- Skenario 3 (Terbaik): Kernel Polynomial, C=1.0, Gamma=Scale (Akurasi Latih: 100.00% | Akurasi Uji: 83.39%)

2) Log Evaluasi CNN Klasik

Pengujian dilakukan terhadap arsitektur dasar (*from scratch*) dengan menguji variasi *optimizer*, *learning rate*, dan parameter regularisasi.

- Skenario 1: Optimizer Adam, LR 0.001, Batch 32, Dropout 0.2 (Val Accuracy: 71.94%)
- Skenario 2: Optimizer SGD, LR 0.01, Batch 64, Dropout 0.4 (Val Accuracy: 73.55%)
- Skenario 3 (Terbaik): Optimizer Adam, LR 0.0001, Batch 32, Dropout 0.3 (Val Accuracy: 82.74%)

3) Log Evaluasi Hybrid (CNN + SVM)

Pengujian dilakukan dengan menggunakan fitur konvolusi statis yang diklasifikasikan oleh SVM.

- Skenario 1 (RBF, C=1.0): Akurasi 86%, F1-Score: 0.86.
- Skenario 2 (Linear, C=1.0 - Terbaik): Akurasi 87%, F1-Score: 0.87.
- Skenario 3 (RBF, C=10.0): Akurasi 87%, F1-Score: 0.87.

4) Log Evaluasi MobileNetV2

Eksplorasi dilakukan pada *optimizer*, *batch size* dan *dropout* untuk arsitektur ringan.

- Skenario 1: Drop 0.2, LR 0.0001 (Akurasi: 87.00%)
- Skenario 2: Batch 32, Drop 0.5, LR 0.001 (Akurasi: 87.67%)
- Skenario 3 (Terbaik): Batch 64, Adam, Drop 0.2, LR 0.001 (Akurasi: 91.00%)

- Skenario 4: SGD, Drop 0.2, LR 0.001 (Akurasi: 70.00%)

5) Log Evaluasi VGG16

Pengujian menekankan pada sensitivitas *learning rate* dan *dropout* karena kapasitas parameter yang besar.

- Skenario 1: LR 0.0001, Drop 0.5, Adam (Val Accuracy: 89.69%)
- Skenario 2 (Terbaik): LR 0.0001, Drop 0.3, Adam (Val Accuracy: 92.81% -> Final Testing: 93.00%)
- Skenario 3: LR 0.00001, Drop 0.5, Adam (Val Accuracy: 85.31%)
- Skenario 4: LR 0.001, Drop 0.4, SGD (Val Accuracy: 80.62%)

6) Log Evaluasi ResNet50

Pengujian menggunakan *learning rate* makro yang sangat kecil untuk mengatasi masalah degradasi gradien.

- Skenario 1: LR 0.0001, Drop 0.5, Adam (Val Accuracy: 60.62% -> Final Testing: 53.33%)
- Skenario 2: LR 0.0002, Drop 0.5, Adam (Val Accuracy: 53.12%)
- Skenario 3: LR 0.00007, Drop 0.4, Adam (Val Accuracy: 53.44%)
- Skenario 4: LR 0.0001, Drop 0.3, RMSprop (Val Accuracy: 57.50%)